Studium Magisterskie

Analiza Danych Big Data

Mateusz Kadłubowski
77620

Predykcja dziennych zwrotów Bitcoina ze szczególnym uwzględnieniem wpływu zmiennych makroekonomicznych

Praca magisterska
Pod kierunkiem naukowym
Dr Katarzyny Bech-Wysockiej
Instytut Ekonometrii

Warszawa 2025

Spis Treści

1 Wstęp 4

2 Przegląd literatury 6

2.1 Analiza zachowania cen i zwrotów Bitcoina jako problem predykcji szeregów czasowych 6

2.2 Zastosowanie technik uczenia maszynowego w analizie i prognozowaniu rynków finansowych 9

2.3 Znaczenie czynników makroekonomicznych w kształtowaniu cen Bitcoina 12

2.4 Przegląd dotychczasowych badań nad predykcją Bitcoina 17

3 Dane i metodyka 19

3.1 Źródła danych 19

3.1.1 Dane cenowe 19

3.1.2 Dane makroekonomiczne 20

3.1.3 Dane On-Chain 21

3.2 Wstępna analiza i przetwarzanie danych 21

3.2.1 Czyszczenie i agregacja danych 21

3.2.2 Analiza eksploracyjna 22

3.3 Opis zastosowanych modeli predykcyjnych 43

3.3.1 ARIMA jako model bazowy 43

3.3.2 LSTM jako główny model predykcji 44

3.3.3 Modele z dodatkowymi zmiennymi 47

3.4 Metody oceny efektywności modelu 54

3.4.1 Metryki błędu 54

3.4.2 Walidacja wyników na zbiorze testowym. 56

4 Wyniki i analiza 57

4.1 Wyniki działania modeli predykcyjnych 57

4.2 Porównanie efektywności zastosowanych metod 59

4.3 Znaczenie zmiennych w predykcji cen Bitcoina 60
4.4 Dyskusja nad wynikami i ich praktycznym zastosowaniem 61
5 Wnioski 63
6 Bibliografia 65
7 Załączniki 70
7.1 Spis wykresów 70
7.2 Spis Tabel 70
7.3 Streszczenie pracy 71
7.4 Pozostałe załączniki 72

1 Wstęp

Rynek kryptowalut powstał wraz z publikacją białej księgi Bitcoina (Nakamoto, 2008), której celem było zaproponowanie bezpośredniego, pozbawionego zaufanej strony pośredniej systemu płatności opartego na sieci zdecentralizowanej (ang. peer-to-peer). Od tego czasu Bitcoin (BTC) stał się najważniejszym kryptoaktywem – wyznacza kierunek całego rynku i stanowi główne odniesienie dla inwestorów oraz badań naukowych. Jego notowania cechuje bardzo wysoka zmienność i okresowa spekulacyjność, ale jednocześnie widoczne jest dojrzewanie rynku: rosnąca płynność, udział inwestorów instytucjonalnych oraz coraz silniejsze powiązania z tradycyjnymi rynkami i czynnikami makroekonomicznymi. W tym kontekście predykcja krótkoterminowych zmian Bitcoina jest interesująca zarówno poznawczo – weryfikacja hipotezy efektywności rynku i faktów stylizowanych, jak i praktycznie – zarządzanie ryzykiem oraz testowanie użyteczności modeli klasycznych i głębokiego uczenia w realistycznych warunkach.

Celem głównym pracy jest ocena skuteczności modeli klasycznych i metod głębokiego uczenia w prognozowaniu dziennych zwrotów logarytmicznych (log-zwroty) Bitcoina. Celem pobocznym jest zbadanie wpływu zmiennych makroekonomicznych na notowania Bitcoina oraz ocena czy uwzględnienie tych zmiennych w modelach prognostycznych poprawia jakość predykcji względem modeli opartych wyłącznie na danych rynkowych, takich jak zmienne świecowe, techniczne czy on-chain.[1]

Wybór tematu wynika z rosnącego znaczenia Bitcoina oraz jego coraz silniejszych powiązań z rynkami tradycyjnymi (akcje, polityka monetarna, dolar amerykański, surowce). Zmienność BTC stawia wysokie wymagania modelom predykcyjnym i stanowi naturalny poligon do testowania podejść opartych na uczeniu maszynowym. Jednocześnie literatura empiryczna nie daje jednoznacznych rozstrzygnięć: część prac raportuje przewagi wybranych algorytmów, inne potwierdzają losowość krótkoterminowych zmian cen. Wartością dodaną niniejszej pracy jest porównanie modeli w rygorystycznej procedurze ewaluacyjnej oraz ocena roli zmiennych makroekonomicznych w krótkim horyzoncie, z zachowaniem praktycznych ograniczeń stosowanych w rzeczywistych zadaniach prognostycznych.

Zakres pracy obejmuje analizę dziennych log-zwrotów Bitcoina na podstawie danych historycznych z lat 2014–2025. Badanie koncentruje się na krótkoterminowej prognozie

[1] Zmienne on-chain to wskaźniki obliczane na podstawie danych zapisanych w łańcuchu bloków (ang. *blockchain*), odzwierciedlające aktywność sieci i uczestników rynku.

jednodniowej (T+1) z wykorzystaniem modeli ARIMA oraz LSTM, które pełnią odpowiednio rolę klasycznego punktu odniesienia oraz nowoczesnego modelu sekwencyjnego opartego na głębokim uczeniu. W analizie uwzględniono również warianty rozszerzone o dodatkowe zmienne, w tym czynniki makroekonomiczne.

Ograniczenia pracy wynikają z przyjętego zakresu i charakteru danych. Po pierwsze, analiza skupia się wyłącznie na krótkim horyzoncie prognozy, co ogranicza możliwość oceny długookresowych zależności. Po drugie, okres badawczy został zawężony do lat 2014–2025 ze względu na dostępność i spójność danych. Po trzecie, zestaw modeli obejmuje jedynie ARIMA i LSTM, co oznacza, że nie uwzględniono innych podejść nieliniowych czy hybrydowych. Po czwarte, pominięto dane o wysokiej częstotliwości oraz aspekty mikrostruktury rynku. Celem pracy jest ocena mocy predykcyjnej modeli, a nie opracowanie strategii inwestycyjnych.

Praca została podzielona na pięć rozdziałów. Po wstępie zawartym w rozdziale 1, rozdział 2 przedstawia przegląd literatury dotyczącej właściwości statystycznych cen i zwrotów Bitcoina, zastosowań metod ekonometrycznych oraz uczenia maszynowego w analizie finansowej, a także znaczenia czynników makroekonomicznych w prognozowaniu kryptowalut i przegląd przeszłych badań dotyczących predykcji Bitcoina. Rozdział 3 opisuje dane, ich źródła i przygotowanie, zawiera analizę eksploracyjną, a także opisy metod badawczych, w tym specyfikację modeli ARIMA i LSTM oraz zastosowane miary oceny skuteczności prognoz i walidacji na zbiorze testowym. Rozdział 4 prezentuje wyniki analiz empirycznych, porównanie jakości prognoz pomiędzy modelami i ocenę wpływu zmiennych na ich skuteczność, a także porównanie z literaturą. Rozdział 5 zawiera podsumowanie uzyskanych wyników, główne wnioski oraz propozycje dalszych kierunków badań.

2 Przegląd literatury

W tym rozdziale zaczynam od teoretycznych podstaw badań nad finansowymi szeregami czasowymi, potem przechodzę do różnych technik ich modelowania i czynników makroekonomicznych, które oddziałują w dużej mierze na ceny aktywów finansowych, w tym w ostatnich latach także na Bitcoina. W ostatniej części przywołuję wnioski z poprzednich badań na temat predykcji notowań BTC.

2.1 Analiza zachowania cen i zwrotów Bitcoina jako problem predykcji szeregów czasowych

Ceny a log-zwroty – stacjonarność

Ceny aktywów finansowych, w tym Bitcoina, charakteryzują się niestacjonarnością – ich poziom zmienia się w czasie w sposób zależny od trendów, wydarzeń rynkowych i czynników fundamentalnych. Oznacza to, że podstawowe parametry szeregu, takie jak średnia czy wariancja, nie pozostają stałe. Brak stacjonarności prowadzi do problemów ekonometrycznych, takich jak ryzyko regresji pozornych, niestabilność parametrów i błędne wnioski statystyczne, a także utrudnia prognozowanie, przez co przed analizą konieczne jest testowanie i odpowiednia transformacja danych. Problem ten jest dobrze opisany w literaturze ekonometrycznej (Enders, 2014) i dotyczy praktycznie wszystkich rynków finansowych.

Aby możliwe było zastosowanie narzędzi analitycznych, najczęściej przekształca się ceny w stopy zwrotu, a w szczególności w logarytmiczne stopy zwrotu, które najczęściej osiągają stacjonarność i mają wiele zalet, takich jak addytywność w czasie, większa stabilność wariancji oraz bardziej odpowiednie własności statystyczne do modelowania (Tsay R. S., 2010). W literaturze dotyczącej Bitcoina przyjmuje się zazwyczaj, że poziomy cen mają charakter niestacjonarny, natomiast logarytmiczne stopy zwrotu można traktować jako stacjonarne w sensie słabym – ich średnia jest zbliżona do zera, a wariancja pozostaje względnie stabilna. Badania empiryczne, m.in. testy ADF, potwierdzają, że szeregi log-zwrotów Bitcoina można traktować jako stacjonarne (Anand, 2025). Dzięki temu log-zwroty stanowią podstawową zmienną w analizach predykcyjnych szeregów finansowych, w tym Bitcoina.

Fakty stylizowane zwrotów logarytmicznych Bitcoina

Szeregi czasowe stóp zwrotu aktywów finansowych charakteryzują się regularnościami określanymi mianem faktów stylizowanych. Po raz pierwszy zostały one wskazane przez

Mandelbrota (1963), a następnie szerzej usystematyzowane przez Conta (2001). Główne fakty stylizowane to:

Brak autokorelacji w zwrotach

Oznacza to, że same stopy zwrotu nie wykazują istotnych zależności liniowych w czasie. Wiedza o wartości zwrotu w jednym okresie nie pozwala zatem prognozować wartości w okresie następnym. Zjawisko to interpretuje się jako przejaw słabej efektywności rynku, zgodnie z którą ceny aktywów odzwierciedlają wszystkie dostępne informacje i zmieniają się w sposób bliski losowemu.

Autokorelacja w wariancji

Chociaż same zwroty są w większości niezależne, ich wariancja wykazuje trwałe zależności w czasie. W praktyce oznacza to, że okresy wysokiej zmienności mają tendencję do występowania po sobie, podobnie jak okresy niskiej zmienności.

Grube ogony rozkładów

Empiryczne rozkłady stóp zwrotu znacząco odbiegają od normalności. Prawdopodobieństwo wystąpienia dużych i skrajnych zmian cenowych jest znacznie wyższe, niż wynikałoby to z rozkładu Gaussa. Zjawisko to wiąże się z leptokurtozą i wynika z częstszego pojawiania się epizodów paniki lub euforii na rynkach finansowych.

Asymetria rozkładu

Rozkłady stóp zwrotu często nie są symetryczne. W wielu przypadkach obserwuje się przewagę gwałtownych spadków nad dużymi wzrostami, co wynika z silniejszej reakcji inwestorów na informacje negatywne niż pozytywne. Tego rodzaju asymetria ma istotne znaczenie dla oceny ryzyka inwestycyjnego, gdyż standardowe modele zakładające symetrię rozkładów mogą nie oddawać prawidłowo rzeczywistej dynamiki rynku.

Długa pamięć w zmienności

Zmienność stóp zwrotu wykazuje trwałość. Oznacza to, że szoki w wariancji nie wygasają natychmiast, lecz wpływają na rynek przez dłuższy czas.

W literaturze empirycznej poświęconej kryptowalutom potwierdzono, że log-zwroty Bitcoina podlegają tym samym regularnościom. Tang i współautorzy (2025), analizując dane wysokoczęstotliwościowe, wskazali, że log-zwroty BTC nie wykazują istotnej autokorelacji liniowej, a jednocześnie charakteryzują się silnymi efektami klastrowania zmienności. Autorzy udokumentowali także wyraźne odstępstwa od normalności, proponując rozkład q-Gaussa jako lepsze przybliżenie empirycznych danych. Abdullaev i Ibragimov (2025) potwierdzili obecność grubych ogonów w rozkładach zwrotów, estymując indeks ogona w przedziale 2,1–2,6. Wynik ten sugeruje skończoną wariancję, ale jednocześnie możliwość nieskończonej czwartej chwili, co odróżnia log-zwroty BTC od wielu tradycyjnych aktywów finansowych. Autorzy zwrócili również uwagę na trwałe efekty pamięci w zmienności, wskazując, że Bitcoin wpisuje się w ogólny schemat faktów stylizowanych, choć w wielu przypadkach zjawiska te są bardziej nasilone niż na rynkach klasycznych.

Efektywność rynku i hipoteza błądzenia losowego

Koncepcja efektywności rynku finansowego jest jednym z kluczowych zagadnień w ekonomii i finansach. Została sformułowana przez Famę (1970, str. 383), który stwierdził, że „*rynek jest efektywny, jeżeli ceny w pełni odzwierciedlają wszystkie dostępne informacje. W zależności od rodzaju informacji rozróżnia się trzy formy efektywności: słabą, półsilną i silną. W wersji słabej ceny zawierają całą informację historyczną, w półsilnej uwzględniają także wszystkie publicznie dostępne dane fundamentalne, a w silnej – również informacje poufne.*”

Z hipotezą efektywności wiąże się pojęcie błądzenia losowego (*random walk*), zgodnie z którym zmiany cen aktywów są całkowicie nieprzewidywalne i mają charakter losowy. Oznacza to, że dzisiejsza cena stanowi najlepsze przybliżenie ceny jutrzejszej, a log-zwroty zachowują się jak losowy szum. To właśnie Samuelson (1965) formalnie dowiódł, że jeśli rynek jest efektywny, ceny muszą podążać losowym spacerem. W konsekwencji inwestor nie jest w stanie systematycznie uzyskiwać ponadprzeciętnych zysków na podstawie informacji, które są już dostępne na rynku.

W literaturze poświęconej Bitcoinowi wyniki dotyczące efektywności są niejednoznaczne. Urquhart (2016) wykazał, że we wczesnych latach istniały istotne odstępstwa od efektywności, co mogło stwarzać możliwości uzyskiwania ponadprzeciętnych zysków. Wraz z dojrzewaniem rynku stopień efektywności wzrastał, a przewidywalność krótkoterminowych zwrotów malała. Podobne wnioski formułuje Bariviera (2017), który stwierdził brak autokorelacji w zwrotach,

a więc zgodność z hipotezą efektywności w sensie słabym, jednocześnie wskazując na silną pamięć w wariancji.

Niektóre badania sugerują, że poziom efektywności Bitcoina zmienia się w czasie. Tiwari i współautorzy (2018) zaproponowali koncepcję dynamicznej efektywności, zgodnie z którą Bitcoin przechodzi przez okresy większej i mniejszej przewidywalności, zależnie od fazy cyklu rynkowego. Kristoufek (2018) natomiast zauważył, że w zależności od przyjętej metody badawczej i badanego okresu Bitcoin może zachowywać się zarówno jak aktywo efektywne, jak i nieefektywne.

Podsumowując, badania empiryczne wskazują, że log-zwroty Bitcoina w krótkim horyzoncie czasowym w dużej mierze odpowiadają założeniom hipotezy błądzenia losowego. Jednocześnie jednak niektóre prace dokumentują odchylenia od pełnej efektywności, szczególnie w początkowych fazach rozwoju, co sprawia, że rynek kryptowalut postrzegany jest jako system znajdujący się w procesie stopniowego dojrzewania.

2.2 Zastosowanie technik uczenia maszynowego w analizie i prognozowaniu rynków finansowych

Pierwsze próby ilościowego modelowania rynków finansowych sięgają lat 30. XX wieku, a wraz z pracami Boxa i Jenkinsa (1970) upowszechniły się modele szeregów czasowych, takie jak ARIMA. W kolejnych dekadach rozwinięto modele zmienności, m.in. GARCH (Engle, 1982; Bollerslev, 1986), które pozwalały lepiej opisywać właściwości zwrotów. Dynamiczny rozwój metod uczenia maszynowego od lat 90. XX wieku wprowadził natomiast zupełnie nowe narzędzia, zdolne do uchwycenia złożonych i nieliniowych zależności. W tym rozdziale przedstawiony zostanie przekrój tych podejść – od klasycznych modeli ekonometrycznych po nowoczesne algorytmy uczenia maszynowego.

Modele klasyczne

Modele ARIMA (autoregressive integrated moving average), zaproponowane przez Boxa i Jenkinsa (1970), należą do podstawowych narzędzi analizy szeregów czasowych i od dekad stanowią punkt odniesienia w badaniach empirycznych. Ich główną zaletą jest możliwość uchwycenia liniowych zależności i krótkookresowych autokorelacji w stacjonarnych szeregach czasowych. Modele te dobrze sprawdzają się tam, gdzie kluczowe znaczenie mają zależności pomiędzy kolejnymi obserwacjami, jednak ich ograniczeniem pozostaje brak zdolności do uchwycenia nieliniowych efektów i zmienności charakterystycznej dla danych finansowych.

ARIMA, ze względu na swoją przejrzystość i interpretowalność, jest często wykorzystywana jako model bazowy, do którego porównuje się skuteczność metod bardziej złożonych.

W literaturze często stosuje się także alternatywne podejścia. Do najważniejszych należą modele GARCH (Engle, 1982; Bollerslev, 1986), które umożliwiają modelowanie i prognozowanie zmienności stóp zwrotu, a także modele VAR (Sims, 1980), pozwalające badać współzależności pomiędzy wieloma zmiennymi jednocześnie, np. rynkiem kryptowalut i czynnikami makroekonomicznymi. W niniejszej pracy zdecydowano się jednak skupić na badaniu autokorelacji log-zwrotów przy pomocy klasycznego modelu ARIMA, traktując go jako punkt odniesienia dla bardziej złożonych metod opartych na uczeniu maszynowym.

Modele uczenia maszynowego

Uczenie maszynowe różni się od klasycznych metod ekonometrycznych przede wszystkim podejściem do modelowania: zamiast stawiać silne założenia co do struktury danych i rozkładów, koncentruje się na algorytmicznym dopasowaniu modelu do danych oraz maksymalizacji zdolności predykcyjnych (Hastie i in., 2009). W rezultacie modele te są bardziej elastyczne i lepiej przystosowane do uchwycenia nieliniowości czy złożonych interakcji pomiędzy zmiennymi, które w finansach występują bardzo często. Do najprostszych podejść należy regresja liniowa, która stanowi naturalne rozszerzenie klasycznych metod ekonometrycznych i pozwala na estymację zależności pomiędzy zwrotami a wybranym zestawem zmiennych objaśniających. Jej ograniczeniem pozostaje jednak założenie liniowości, które w przypadku rynków finansowych często okazuje się zbyt restrykcyjne. Alternatywą są modele nieliniowe, takie jak drzewa decyzyjne oraz ich zespoły, w tym popularny algorytm XGBoost (Chen i Guestrin, 2016), które umożliwiają uchwycenie bardziej złożonych zależności i interakcji pomiędzy zmiennymi. Dodatkową zaletą tych metod jest możliwość oceny istotności predyktorów i selekcji najbardziej informacyjnych zmiennych, co pozwala lepiej zrozumieć strukturę danych finansowych.

Modele uczenia głębokiego i sieci rekurencyjne

W odróżnieniu od klasycznych metod uczenia maszynowego, takich jak regresja czy drzewa decyzyjne, które bazują na ręcznie dobranych cechach i stosunkowo prostych zależnościach pomiędzy zmiennymi, uczenie głębokie (deep learning) opiera się na wielowarstwowych sieciach neuronowych zdolnych do samodzielnego wydobywania reprezentacji z danych (Goodfellow i in., 2016). Dzięki temu umożliwia modelowanie bardziej złożonych, nieliniowych zależności charakterystycznych dla rynków finansowych. Jedną z pierwszych

architektur zastosowanych do analizy danych sekwencyjnych były sieci RNN (Recurent Neural Network) w których każda obserwacja przekazywana jest wraz z ukrytą reprezentacją do kolejnego kroku czasowego. Pozwala to odwzorowywać zależności dynamiczne, co czyni je szczególnie atrakcyjnymi w prognozowaniu szeregów czasowych. Ich ograniczeniem okazał się jednak problem zanikającego i eksplodującego gradientu, który znacząco utrudniał uczenie w przypadku dłuższych sekwencji (Bengio i in., 1994).

Rozwiązaniem tych trudności stały się sieci LSTM (Long Short-Term Memory), zaproponowane przez Hochreitera i Schmidhubera (1997). Ich architektura opiera się na zastosowaniu mechanizmu bramek kontrolujących przepływ informacji, co pozwala modelowi przechowywać lub odrzucać dane w zależności od ich znaczenia. Dzięki temu LSTM potrafią uchwycić długookresowe zależności w szeregach czasowych i unikają problemu zanikającego gradientu. Znalazły one szerokie zastosowanie w finansach, gdzie umożliwiają modelowanie nieliniowych zależności oraz efektów pamięci w szeregach zwrotów. Fischer i Krauss (2018) wykazali, że sieci LSTM przewyższają klasyczne modele, w tym logistyczną regresję i metody ensemble takie jak lasy losowe czy algorytmy boostingowe, w prognozowaniu kierunku zmian indeksu S&P500, co potwierdza ich użyteczność w kontekście rynków kapitałowych.

W literaturze pojawiły się również alternatywy wobec LSTM. Sieci GRU (Gated Recurrent Unit), zaproponowane przez Cho i współautorów (2014), stanowią uproszczoną wersję LSTM, w której połączono bramki zapominania i wejścia, co zmniejsza złożoność obliczeniową przy zachowaniu porównywalnej skuteczności. Nowszym podejściem są architektury oparte na mechanizmach uwagi, takie jak Transformery (Vaswani i in., 2017), które rezygnują z rekurencji i równolegle przetwarzają sekwencje, umożliwiając efektywne modelowanie długookresowych zależności. Choć ich zastosowania w finansach dopiero się rozwijają, pierwsze wyniki wskazują na ich potencjał w analizie dużych i złożonych zbiorów danych.

W niniejszej pracy centralne miejsce zajmuje jednak model LSTM, traktowany jako najbardziej reprezentatywna metoda sekwencyjna, pozwalająca ocenić, czy głębokie uczenie oferuje przewagę nad klasycznymi podejściami, takimi jak ARIMA.

Wyniki badań nad zastosowaniem uczenia maszynowego w prognozowaniu rynków finansowych są niejednoznaczne. Część literatury wskazuje, że metody ML lub DL przewyższają klasyczne podejścia, zwłaszcza w sytuacjach, gdy do prognozy włączane są dodatkowe źródła informacji, takie jak wskaźniki analizy technicznej czy czynniki makroekonomiczne (Gu i in, 2020; Atsalakis i Valavanis, 2009; Fischer i Krauss, 2018). W

takich przypadkach algorytmy uczenia maszynowego są w stanie uchwycić nieliniowe zależności i skomplikowane interakcje pomiędzy zmiennymi, co przekłada się na wyższą jakość predykcji. Trzeba jednak pamiętać, że choć autorzy podkreślają obiecujące wyniki, to przewagi są często marginalne, nietrwałe w czasie i silnie zależne od doboru zmiennych oraz okresu testowego. Dodatkowo, metody głębokiego uczenia są podatne na przeuczenie (*overfitting*) i charakteryzują się ograniczoną interpretowalnością, co sprawia, że w praktycznych zastosowaniach mogą okazać się niewystarczające do konsekwentnego generowania zysków. Dodatkowo, liczne badania dowodzą, że w krótkim horyzoncie prognozy oparte wyłącznie na samych stopach zwrotu nie pozwalają modelom ML znacząco przewyższyć prostych benchmarków, takich jak proces błądzenia losowego czy modele ARIMA (Aminimehr i in, 2022; Nico Beck i in.,2025).

Na tym tle w niniejszej pracy ARIMA pełni rolę klasycznego punktu odniesienia, natomiast LSTM stanowi przykład nowoczesnego modelu sekwencyjnego. Analiza ma na celu sprawdzenie, czy uczenie głębokie rzeczywiście oferuje przewagę w prognozowaniu zwrotów Bitcoina oraz czy uwzględnienie dodatkowych zmiennych, w szczególności makroekonomicznych, poprawia jakość predykcji. Szczegółowy przegląd literatury dotyczącej badań empirycznych nad prognozowaniem Bitcoina zostanie omówiony w odrębnym podrozdziale.

2.3 Znaczenie czynników makroekonomicznych w kształtowaniu cen Bitcoina

W początkowym okresie swojego istnienia Bitcoin funkcjonował jako aktywo w dużej mierze odizolowane od globalnego systemu finansowego. Jego wycena była kształtowana przede wszystkim przez czynniki wewnętrzne, takie jak rozwój infrastruktury giełdowej, wydarzenia regulacyjne czy kolejne halvingi[2]. Dopiero wraz ze wzrostem kapitalizacji rynkowej oraz rosnącym zainteresowaniem ze strony inwestorów instytucjonalnych zaczęto obserwować silniejsze powiązania z tradycyjnymi rynkami finansowymi i polityką monetarną banków centralnych.

Charakterystyczną cechą tego aktywa pozostaje wysoka zmienność, która od początku budziła wątpliwości co do jego użyteczności jako bezpiecznej przystani. Ograniczona podaż zakorzeniona w protokole oraz dojrzewanie rynku sprawiają jednak, że coraz częściej wskazuje

[2] Halving to zaprogramowane w protokole Bitcoina zmniejszenie o 50% nagrody za wydobycie bloku (tzw. subsydium) co 210 000 bloków, co ogranicza tempo emisji i prowadzi do maksymalnej podaży 21 mln BTC (Nakamoto, 2008)

się na jego podobieństwa do złota – klasycznego środka przechowywania wartości. Z jednej strony BTC wciąż reaguje na nastroje inwestorów i w okresach wzrostu awersji do ryzyka zachowuje się jak typowe aktywo ryzykowne, silnie skorelowane z rynkiem akcji. Z drugiej strony, w ostatnich latach obserwuje się, że jego spadki są coraz bardziej umiarkowane – przykładem może być korekta indeksu S&P500 w kwietniu 2025 roku, podczas której Bitcoin okazał się odporniejszy na spadki niż tradycyjne indeksy giełdowe.

Z czasem, ta kryptowaluta zaczęła odgrywać coraz istotniejszą rolę w portfelach inwestorów instytucjonalnych. Wraz z rozwojem instrumentów pochodnych, takich jak kontrakty futures czy ETF-y[3] w 2023 roku, jej zachowanie cenowe coraz wyraźniej zaczęło podlegać tradycyjnym uwarunkowaniom makroekonomicznym. W literaturze podkreśla się, że we wcześniejszych latach korelacje Bitcoina z innymi klasami aktywów były bliskie zeru, co sprzyjało narracji o jego wyjątkowości (Baur i in., 2018). Obecnie jednak badania wskazują na rosnącą współzależność z rynkiem akcji, surowcami, dolarem amerykańskim oraz polityką monetarną Rezerwy Federalnej szczególnie w okresach większych turbulencji (Wang i in., 2022; Lin i in., 2025).

W świetle powyższych tendencji BTC nie powinien być analizowany w oderwaniu od globalnych czynników makroekonomicznych, takich jak inflacja, poziom stóp procentowych, zmienność rynkowa czy dynamika podaży pieniądza. Korelacje te są przy tym zmienne w czasie i szczególnie istotne w okresach turbulencji, kiedy aktywo to bywa traktowane naprzemiennie – jako ryzykowna inwestycja albo jako potencjalna alternatywa dla złota i innych bezpiecznych przystani.

Jednym z najczęściej analizowanych powiązań jest korelacja Bitcoina z rynkiem akcji, w szczególności z indeksem S&P500, który uchodzi za globalny barometr nastrojów inwestorów. We wczesnych latach istnienia BTC jego notowania były niemal niezależne od tradycyjnych indeksów giełdowych, co świadczyło o jego wyjątkowości wśród instrumentów finansowych i potencjalnej funkcji dywersyfikacyjnej. Jednak od 2020 roku obserwuje się systematyczny wzrost współzależności pomiędzy Bitcoinem a rynkiem akcji. Badania empiryczne wskazują, że szczególnie w okresach turbulencji finansowych BTC zachowuje się podobnie jak spółki

[3] ETF (*Exchange Traded Fund*) to fundusz inwestycyjny notowany na giełdzie, który odwzorowuje określony indeks lub grupę aktywów, umożliwiając inwestorom dywersyfikację przy niskich kosztach i wysokiej płynności.

technologiczne (Nasdaq 100, S&P500), co potwierdza jego charakter ryzykownego aktywa, czyli aktywa podatnego na zmiany sentymentu inwestorów (Wu., 2025).

Istotnym uzupełnieniem tej relacji jest związek Bitcoina z indeksem zmienności VIX, określanym mianem „indeksu strachu". VIX odzwierciedla oczekiwaną zmienność rynku akcji i rośnie w momentach zwiększonej awersji do ryzyka. Literatura wskazuje, że w okresach wysokiego VIX Bitcoin traci na wartości, podobnie jak rynek akcji, co sugeruje brak funkcji stabilizującej wobec nagłych szoków rynkowych (Wang i in., 2022). Oznacza to, że w chwilach niepewności BTC nie pełni jeszcze w pełni roli bezpiecznej przystani, lecz zachowuje się jak klasyczne aktywo ryzykowne.

Na korelacje Bitcoina wpływają również zmiany na rynku długu, w szczególności rentowności dziesięcioletnich obligacji skarbowych Stanów Zjednoczonych (US10Y), które stanowią kluczowy punkt odniesienia dla globalnych kosztów kapitału. Wzrost rentowności US10Y wiąże się ze wzrostem realnych stóp procentowych, co ogranicza atrakcyjność aktywów spekulacyjnych i kapitałowych, w tym Bitcoina. Badania empiryczne wskazują na ujemną zależność pomiędzy Bitcoinem a US10Y, co oznacza, że w okresach wzrostu rentowności obligacji odpływ kapitału z rynku kryptowalut staje się bardziej widoczny (Kartal i Öztürk, 2022)

Złoto od dekad pełni funkcję klasycznego aktywa bezpiecznego, chroniącego wartość kapitału w okresach podwyższonej niepewności makroekonomicznej czy rynkowej. W literaturze często porównuje się je z Bitcoinem w kontekście roli „cyfrowego złota". Starsze badania wskazywały na zerową korelację między Bitcoinem a złotem, co oznaczało, że BTC pełnił jedynie funkcję narzędzia do dywersyfikacji portfela, jednak z istotnie wyższym ryzykiem niż klasyczne aktywa bezpieczne (Klein i in., 2018). Autorzy podkreślali, że Bitcoin w okresach hossy zachowuje się jak aktywo czysto spekulacyjne, a jego związek ze złotem był wówczas praktycznie nieobecny. Kolejne badania poszerzyły tę perspektywę, analizując wpływ niepewności polityki gospodarczej (EPU) na zachowanie Bitcoina i złota (Paule-Vianez i in., 2020). Wyniki pokazały, że EPU istotnie zwiększa zmienność obu aktywów, a w skrajnych warunkach niepewności Bitcoin może pełnić częściowo funkcję „safe haven", podobnie do złota. Jednocześnie autorzy zauważyli, że BTC wciąż zachowuje cechy aktywa opartego na sentymencie i wysokiej zmienności, co odróżnia go od stabilniejszego złota. Najnowsze prace koncentrują się na relacji BTC–złoto w kontekście kryzysów, takich jak pandemia COVID-19 (Ibrahim i in., 2024). Wskazują one na istnienie długoterminowej zależności pomiędzy tymi

aktywami zarówno przed, jak i w czasie pandemii, przy czym w okresie kryzysu pojawiła się dodatkowo krótkoterminowa transmisja zmienności. Oznacza to, że w warunkach turbulencji Bitcoin coraz częściej zachowuje się podobnie do złota, przyjmując rolę cyfrowej alternatywy dla klasycznej bezpiecznej przystani.

Bloomberg Commodity Index (BCOM) obejmuje szeroki koszyk surowców i stanowi punkt odniesienia dla globalnych trendów towarowych. Bitcoin bywa analizowany jako alternatywa dla surowców w portfelach inwestorów, jednak wspólne czynniki makroekonomiczne, takie jak inflacja czy polityka monetarna, sprawiają, że ich zachowania okresowo się zbliżają. Ben Brayek (2024) wykazał, że w okresach podwyższonej zmienności rośnie korelacja Bitcoina z rynkiem surowców, co ogranicza jego potencjał dywersyfikacyjny. W konsekwencji Bitcoin nie działa jako aktywo stabilizujące, lecz potęguje wahania portfela w czasie kryzysów.

Indeks dolara amerykańskiego (DXY) stanowi ważny wskaźnik globalnych warunków finansowych. Silniejszy dolar zwykle oznacza zaostrzenie tzw. kanału finansowego – droższe finansowanie w USD, spadek przepływów kapitałowych i mniejszy apetyt inwestorów na ryzyko. Tego typu mechanizmy zostały dobrze opisane w literaturze banków centralnych. Badania Banku Rozrachunków Międzynarodowych (BIS) wskazują, że wzrost dolara wiąże się z pogorszeniem warunków kredytowych i spadkiem inwestycji na świecie (Avdjiev i in., 2019). Podobnie Europejski Bank Centralny podkreśla rolę USD jako globalnego czynnika ryzyka (ECB, 2020). W przypadku rynku kryptowalut obserwuje się częste, choć zmienne w czasie, ujemne korelacje pomiędzy DXY a ceną Bitcoina, szczególnie w okresach podwyższonego ryzyka, kiedy inwestorzy ograniczają ekspozycję na bardziej ryzykowne aktywa (Lin i in., 2025).

Inflacja i polityka pieniężna wpływają na Bitcoina w sposób zbliżony do oddziaływania na tradycyjne aktywa ryzykowne. Wyższe odczyty wskaźnika CPI (*Consumer Price Index*) oraz zapowiedzi zaostrzenia polityki pieniężnej przez Fed zwiększają oczekiwania dotyczące stóp procentowych, co przekłada się na wyższą stopę dyskontową i presję na spadek wycen BTC. Badania oparte na danych wysokiej częstotliwości pokazują, że Bitcoin reaguje spadkami na niespodziewane zacieśnienie polityki pieniężnej w USA, a efekt utrzymuje się jeszcze przez kilka dni po decyzji (Ma i in., 2022). Z kolei analizy prowadzone w ramach badań Fed wskazują, że to właśnie szoki dotyczące stóp procentowych i oczekiwań co do ich przyszłego poziomu stanowią jeden z głównych kanałów, przez które informacje makroekonomiczne oddziałują na rynek kryptowalut (Benigno i Rosa, 2023).

Reakcje Bitcoina na publikacje danych inflacyjnych są niejednoznaczne i zależą od sposobu identyfikacji szoków. Wyniki oparte na niespodziewanych odczytach CPI sugerują, że BTC ma tendencję do spadków w dniu publikacji, co podważa tezę o jego krótkoterminowej roli jako zabezpieczenia przed inflacją (Smales, 2023). Inne podejście, oparte na analizach VAR, wskazuje jednak, że w dłuższym horyzoncie inflacja może oddziaływać pozytywnie na Bitcoina, co sugeruje warunkowe i kontekstowe znaczenie tego aktywa jako zabezpieczenia przed inflacją (Choi i Shin, 2021).

W przypadku płynności monetarnej mierzonej agregatem M2 wyniki badań są zróżnicowane. Wskazuje się na krótkookresowe zależności przyczynowe między M2 a ceną Bitcoina, jednak brak jest dowodów na stabilną i trwałą relację w całym badanym okresie. Co więcej, pojawiają się również wyniki sugerujące istnienie sprzężenia zwrotnego, w którym to sam Bitcoin może oddziaływać na zmiany w agregatach pieniężnych (Wang i Sarker, 2022). Podsumowując, stopy procentowe i niespodzianki inflacyjne stanowią istotne źródło krótkoterminowych szoków cenowych na rynku BTC, natomiast M2 należy traktować raczej jako tło cykliczne niż czynnik użyteczny w prognozowaniu jednodniowych log-zwrotów.

Powiązania Bitcoina z czynnikami makroekonomicznymi nie są stałe, lecz zmieniają się w zależności od fazy cyklu rynkowego oraz nastrojów inwestorów. W okresach hossy, gdy dominuje apetyt na ryzyko, BTC zachowuje się podobnie jak aktywa spekulacyjne, silnie korzystając z napływu płynności. Natomiast w momentach wzrostu awersji do ryzyka, spadki na rynkach akcji zwykle przenoszą się także na kryptowaluty, co potwierdzają wyniki badań z wykorzystaniem korelacji kroczących (Wu, 2025). Istotną rolę odgrywają także regulacje rynkowe oraz wewnętrzne cykle specyficzne dla Bitcoina, takie jak halvingi, które mogą chwilowo zmieniać dominujące narracje i osłabiać wpływ czynników makroekonomicznych.

Przegląd badań wskazuje, że wpływ czynników makroekonomicznych na Bitcoina jest szczególnie widoczny w średnich i długich horyzontach, natomiast w krótkim okresie sygnały te są słabe i często ustępują przypadkowej zmienności. Rosnąca współzależność BTC z indeksem S&P500, dolarem amerykańskim czy stopami procentowymi świadczy o tym, że kryptowaluta ta coraz silniej wpisuje się w globalny system finansowy. Zależności te jednak nie zawsze są oczywiste i zależą od badanego okresu.

2.4 Przegląd dotychczasowych badań nad predykcją Bitcoina

W literaturze dotyczącej krótkoterminowego prognozowania kursu Bitcoina można wyróżnić dwa zasadnicze podejścia badawcze. Pierwsze z nich koncentruje się na modelowaniu bezpośrednich poziomów cen, drugie natomiast na analizie i prognozowaniu zwrotów logarytmicznych.

W przypadku prognozowania poziomów cen stosunkowo liczne badania z wykorzystaniem modeli głębokiego uczenia raportują bardzo dobre dopasowania. Na przykład, w pracy Seabe i in. (2023) najwyższą trafność prognoz osiągnął model Bi-LSTM, przewyższając inne architektury rekurencyjne. Podobnie, Dutta i in. (2020) raportowali bardzo dobre wyniki dla modeli uczenia głębokiego. Wykazali również, że zastosowanie sieci GRU ze specjalnym mechanizmem regularyzacji pozwala na uzyskanie lepszych rezultatów niż tradycyjne sieci neuronowe oraz klasyczne LSTM. Również badanie Goodell i in. (2023), w którym połączono metody głębokiego uczenia z narzędziami wyjaśnialnej sztucznej inteligencji (XAI), wskazało na wysokie wartości współczynnika determinacji R^2 oraz stosunkowo niskie błędy prognoz w dla danych z 2022 roku.

Do wynikach na poziomach cen Bitcoina trzeba podchodzić jednak z ostrożnością. Charakteryzują się one silną niestacjonarnością oraz obecnością trendów długookresowych. Z tego względu modelowanie cen sprzyja zjawisku dopasowania do trendu, które może skutkować uzyskaniem wysokich wartości R^2 oraz wizualnie atrakcyjnych dopasowań wykresów, nawet w sytuacji braku realnej mocy prognostycznej. Już klasyczne wyniki Grangera i Newbolda (1974) dotyczące tzw. regresji pozornych wskazywały, że stosowanie niestacjonarnych zmiennych w modelach ekonometrycznych prowadzi do myląco istotnych statystyk. Podobne obserwacje pojawiają się w badaniach nad kursami walut, które – podobnie jak kursy kryptowalut – stanowią szeregi niestacjonarne. Meese i Rogoff (1983) udowodnili, że rozbudowane modele kursów walutowych często ustępują prostemu modelowi losowego spaceru w prognozach poza próbką treningową.

Na problem trendowego dopasowania nakładają się dodatkowe niedoskonałości metodologiczne. Często rezygnuje się z walidacji chronologicznej, zastępując ją kroswalidacją typową dla danych przekrojowych. Do tego dochodzi stosowanie miar jakości prognoz bez odniesienia do prostego punktu odniesienia, co może prowadzić do wyciągania zbyt optymistycznych wniosków (Hyndman i Athanasopoulos, 2021).

W przypadku zwrotów logarytmicznych uzyskiwane wyniki są znacznie mniej spójne. Prace raportujące stosunkowo „dobre” dopasowania (Sung i in., 2022; Wei, 2024) często opierają się na procedurach, które sprzyjają powstawaniu błędów metodologicznych, takich jak stosowanie selekcji cech lub normalizacji na całym zbiorze danych (co prowadzi do wycieku informacji), brak walidacji kroczącej czy niewłaściwe dostosowanie modeli bazowych – przykładem jest użycie procesu ARIMA z różnicowaniem na szeregach, które są już stacjonarne. Dodatkowym problemem jest brak testów statystycznych weryfikujących istotność przewagi nad prostymi punktami odniesienia.

Odmienne wyniki uzyskują prace, w których zastosowano bardziej restrykcyjne reżimy ewaluacyjne. Krähenbühl i Osterrieder (2022), Magner i Hardy (2022) oraz Shintate i Pichl (2019) opierali swoje analizy na ścisłym podziale czasowym, walidacji kroczącej, porównaniu do prognozy naiwnej lub spaceru losowego oraz kontroli ryzyka nadmiernej eksploracji danych. W ich badaniach zdolności predykcyjne okazują się nie większe niż minimalne, a rezultaty są w pełni zgodne z hipotezą rynku efektywnego w słabej formie.

W niniejszym badaniu przyjęto rygorystyczne podejście metodologiczne, którego celem jest uzyskanie wiarygodnych wyników. Po pierwsze, zastosowano benchmark w postaci prostego modelu ARIMA. Po drugie, zastosowano optymalizację parametrów, aby mieć pewność, że wyniki nie zależą od szczegółu technicznego. Po trzecie, zapewniono pełną separację czasową pomiędzy zbiorem uczącym a testowym, a wszystkie procedury skalowania i selekcji cech wykonywane były wyłącznie na danych treningowych, aby uniknąć wycieku informacji. Po czwarte, analizowany horyzont prognozy obejmuje jednodniowe zwroty logarytmiczne.

Dzięki temu uzyskane wyniki nie będą konsekwencją dopasowania trendu czy przecieku informacji, lecz rzetelną oceną krótkoterminowej przewidywalności Bitcoina.

3 Dane i metodyka

W tym rozdziale opisuję wykorzystane zbiory danych oraz sposób ich przygotowania: scalenie, ujednolicenie częstotliwości, standaryzację i wstępną analizę. Następnie przedstawiam ramę modelowania z podziałem cech na bloki informacyjne oraz porównuję model bazowy z wybraną metodą głębokiego uczenia. Na koniec definiuję sposób oceny i walidacji prognoz, tak, aby wyniki były porównywalne i rzetelne. Wszystkie modele zostały zaimplementowane w języku Python (wersja 3.11) w środowisku Jupyter Notebook. Wszystkie użyte biblioteki zostały podane w załącznikach.

3.1 Źródła danych

3.1.1 Dane cenowe

Podstawowym źródłem danych w niniejszej pracy były notowania cenowe Bitcoina, pobrane z serwisu Investing.com. Zakres czasowy obejmuje okres od 17 września 2014 roku do 27 sierpnia 2025 roku. Pozwala na analizę obejmującą ponad dekadę obserwacji uwzględniających kilka pełnych cykli rynkowych Bitcoina (hossa–bessa). Dane zawierały informacje o cenie otwarcia (*Open*), najwyższej cenie w ciągu dnia (*High*), najniższej cenie (*Low*), cenie zamknięcia (*Close*) oraz wolumenie obrotu (*Volume*).

Na potrzeby dalszej analizy jako podstawową zmienną wybrano ceny zamknięcia, które stanowią punkt odniesienia w większości badań empirycznych nad rynkami finansowymi. Na ich podstawie skonstruowano dzienny logarytmiczny zwrot, będący zmienną objaśnianą (*target*) w modelach predykcyjnych. Logarytmiczny zwrot dla dnia t został zdefiniowany następująco:

$$r_t = ln\left(\frac{p_t}{P_{t-1}}\right)$$

gdzie:

r_t – oznacza logarytmiczny zwrot w dniu t

P_t– cenę zamknięcia w dniu t,

P_{t-1} – cenę zamknięcia w dniu poprzednim.

Zastosowanie logarytmicznych zwrotów zamiast prostych stóp zwrotu ma kilka zalet. Przede wszystkim umożliwiają one wygodne sumowanie kolejnych zmian cen, co jest istotne przy analizie dłuższych okresów. Dodatkowo log-zwroty ułatwiają interpretację zmian

procentowych, co ma znaczenie w przypadku aktywów bardzo zmiennych, takich jak Bitcoin. Co więcej, w literaturze ekonomicznej i finansowej log-zwroty są standardem, ponieważ cechują się lepszymi własnościami statystycznymi niż proste zwroty, np. bardziej symetrycznym rozkładem i mniejszą zależnością od poziomu samej ceny.

3.1.2 Dane makroekonomiczne

Drugim blokiem danych w pracy były wskaźniki makroekonomiczne, odzwierciedlające kondycję gospodarki globalnej i sytuację na tradycyjnych rynkach finansowych. Zestaw wykorzystanych zmiennych został przedstawiony w poniższej tabeli, zawierającej ich nazwy, skróty, krótki opis oraz źródła.

Większość zmiennych pochodzi z gospodarki amerykańskiej, co wynika z faktu, że Stany Zjednoczone są pionierem w rozwoju rynku kryptowalut i mają największy wpływ na jego wycenę oraz zmienność.

Zmienna	**Skrót**	**Opis**	**Źródło**
Indeks S&P 500	S&P500	Główny indeks akcji w USA	FRED (fred.stlouisfed.org)
Rentowność obligacji 10Y USA	US10Y	Rentowność 10-letnich obligacji skarbowych USA	FRED (fred.stlouisfed.org)
Cena złota	XAUUSD	Cena złota w USD za uncję	Investing.com
Cena ropy (WTI/Brent)	WTI/Brent	Cena ropy WTI i Brent w USD za baryłkę	FRED (fred.stlouisfed.org)
Bloomberg Commodity Index	BCOM	Indeks towarowy Bloomberga	Investing.com
Indeks dolara (DXY)	DXY	Indeks siły dolara amerykańskiego	Investing.com
Consumer Price Index (CPI)	CPI	Wskaźnik inflacji konsumenckiej w USA	FRED (fred.stlouisfed.org)
M2 Money Supply	M2	Agregat podaży pieniądza M2	FRED (fred.stlouisfed.org)
Federal Funds Rate (FFR)	FFR	Podstawowa stopa procentowa Fed	FRED (fred.stlouisfed.org)

Volatility Index (VIX)	VIX	Indeks zmienności rynku akcji w USA	FRED (fred.stlouisfed.org)

Tabela 1. Źródła danych makroekonomicznych.

3.1.3 Dane On-Chain

W pracy uwzględniono także dane *„on-chain”,* które opisują aktywność sieci Bitcoina oraz zachowania uczestników rynku. Ze strony Glassnode.com pobrano dane dla dwóch zmiennych: hashrate (łączna moc obliczeniowa sieci) oraz wskaźnik MVRV (Market Value to Realized Value), często stosowany jako miara sentymentu inwestorów.

3.2 Wstępna analiza i przetwarzanie danych

Przed zastosowaniem modeli predykcyjnych dane zostały odpowiednio przygotowane. Dodatkowo zrobioną wstępną analizę statystyczną oraz graficzną w celu zidentyfikowaniu wzorców w danych.

3.2.1 Czyszczenie i agregacja danych

Zebrane dane wymagały szeregu działań porządkujących i przekształceń, aby mogły zostać wykorzystane w modelach predykcyjnych.

Radzenie sobie z brakami i synchronizacja częstotliwości

W sensie technicznym dane nie zawierały braków obserwacji, ale szeregi różniły się częstotliwością publikacji i wymagały ujednolicenia. Wszystkie dane zostały dopasowane do częstotliwości dziennej, zgodnej z częstotliwością zmiennej objaśnianianej. Dane miesięczne (CPI, FFR) i tygodniowe (M2) zostały przekształcone do częstotliwości dziennej poprzez uzupełnienie brakujących wartości metodą przeniesienia ostatniej znanej obserwacji (*forward fill*), natomiast wskaźniki on-chain (hashrate, MVRV), raportowane co cztery dni, wygładzono za pomocą interpolacji liniowej. Dzięki temu powstały spójne szeregi czasowe obejmujące wspólny zakres obserwacji od 17 września 2014 roku do 27 sierpnia 2025 roku.

Podział na zestawy danych

Na potrzeby dalszej analizy dane zostały uporządkowane w trzech odrębnych blokach:

- Dane BTC - dzienne ceny OHLC (Open-high-low-close) oraz volume, na podstawie których wyliczono logarytmiczne zwroty i wiele zmiennych technicznych użytych w modelach.

- Dane makroekonomiczne - dla wszystkich indeksów i wskaźników wykorzystano wartości close (dla rynków finansowych) lub wartości końcowe publikowane w danym dniu. Dane te scalono w jedną tabelę, w której każda zmienna stanowiła odrębną kolumnę. W ramach oczyszczania usunięto zbędne informacje (open, high, low), a dane zapisane w plikach CSV w formacie tekstowym (np. wartości w cudzysłowach) zostały przekształcone do formy numerycznej.
- Dane on-chain – obejmujące wskaźniki hashrate i MVRV, po interpolacji liniowej dopasowane do częstotliwości dziennej.

Ostatecznie wszystkie dane zostały zintegrowane w zestandaryzowanych tabelach w formacie CSV, które stanowiły punkt wyjścia do budowy i ewaluacji modeli predykcyjnych.

Standaryzacja

Ze względu na różne skale poszczególnych zmiennych (np. indeksy giełdowe, ceny surowców, stopy procentowe, dane on-chain), przed wprowadzeniem do modeli wszystkie dane zostały poddane standaryzacji. Zastosowano metodę StandardScaler z biblioteki scikit-learn, która transformuje każdą zmienną do postaci o średniej 0 i odchyleniu standardowym 1. Standaryzację przeprowadzono osobno dla każdego zestawu cech, z użyciem parametrów dopasowanych wyłącznie na zbiorze treningowym, co pozwoliło uniknąć problemu przecieku danych.

3.2.2 Analiza eksploracyjna

W tym podrozdziale zawarto analizę eksploracyjną cen i log-zwrotów Bitcoina. Celem tej części jest ogólna charakterystyka badanego szeregu czasowego oraz wstępne wskazanie jego najważniejszych właściwości, które będą miały znaczenie przy dalszym modelowaniu i prognozowaniu.

Wizualizacja cen i log zwrotów Bitcoina w czasie

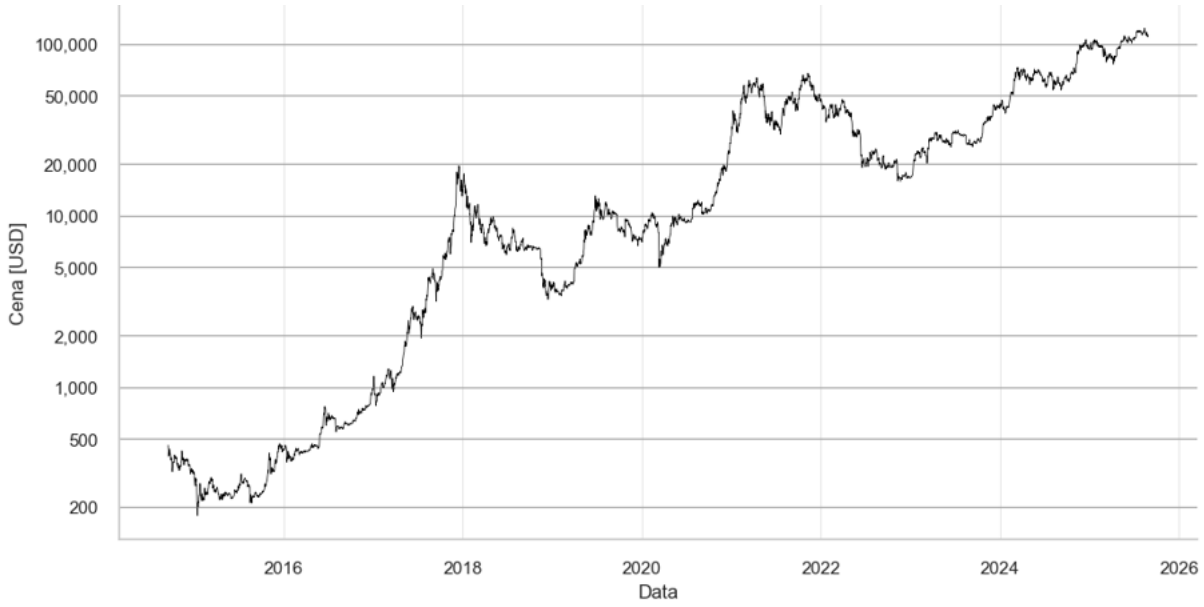

Wykres 1. Cena Bitcoina na skali logarytmicznej ujęta w dolarze amerykańskim (USD)

Cena Bitcoina w badanym okresie charakteryzuje się ogromnym wzrostem. Od wartości rzędu poniżej 200 dolarów w 2015 roku, notowania wzrosły w szczytowych momentach do ponad 100 tys. USD, co oznacza kilkusetny wzrost w dekadę.

Ruchy cenowe Bitcoina mają charakter cykliczny. W kolejnych cyklach hossy i bessy związanych m.in. z halvingami obserwuje się coraz większe skale cenowe, ale jednocześnie zmiany są nieco bardziej wygładzone – wahania procentowe w stosunku do wcześniejszych lat są coraz mniejsze.

Historia cenowa BTC obejmuje także gwałtowne spadki. Najbardziej znany w ostatnich latach dzienny spadek to krach w marcu 2020 roku, kiedy to w związku z globalną paniką na rynkach finansowych związanych z pandemią Covid-19 cena Bitcoina spadła z poziomu powyżej 8 tys. USD do poniżej 5 tys. USD w ciągu jednego dnia. Występują również głębokie długotrwałe korekty m.in. w latach 2018 i 2022, które były naturalnym elementem cyklu rynkowego.

Mimo bardzo wysokiej zmienności krótkookresowej, długoterminowy trend cenowy pozostaje jednoznacznie wzrostowy. Bitcoin z niszowego aktywa stał się jednym z najważniejszych elementów globalnego rynku finansowego, a jego zmiany cenowe coraz częściej powiązane są z wydarzeniami makroekonomicznymi i nastrojami inwestorów a nie z czystą spekulacją.

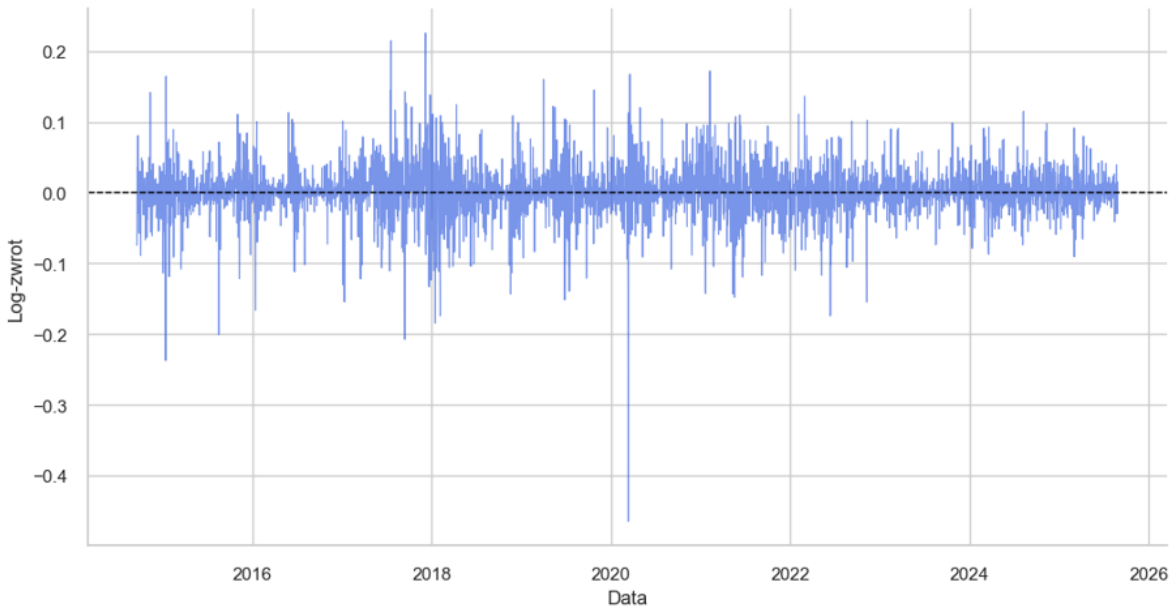

Wykres 2. Dzienne logarytmiczne stopy zwrotu Bitcoina

Wykres dziennych log-zwrotów Bitcoina wskazuje na silną zmienność i duże wahania wokół zera. Widoczny jest brak wyraźnych trendów, co sugeruje stacjonarność szeregu. Charakterystyczne są okresy skupisk podwyższonej zmienności, co dodatkowo utrudnia prognozowanie – szereg jest w dużej mierze zdominowany przez szum losowy.

Rozkład dziennych log-zwrotów BTC

Statystyka	**Wartość**	**Interpretacja**
Liczba obserwacji	3 997	Liczba dni w próbie
Średnia	0,0014	Przeciętny dzienny log-zwrot = około 0,14%
Odchylenie standardowe	0,0358	Przeciętne wahanie = około 3,6% dziennie
Minimum	-0,4647	Największy spadek dzienny to około 46%
1% percentyl	-0,1060	1% najgorszych dni: spadki > -10,6%
5% percentyl	-0,0556	5% najgorszych dni: spadki > -5,6%
Mediana (50%)	0,0013	Połowa dni poniżej 0,13%, połowa powyżej
95% percentyl	0,0541	5% najlepszych dni: wzrosty > 5,4%
99% percentyl	0,1003	1% najlepszych dni: wzrosty > 10%
Maksimum	0,2251	Największy wzrost dzienny = około 22,5%

Tabela 2. Statystyki opisowe dziennych logarytmicznych stóp zwrotu Bitcoina

Dzienna seria log-zwrotów Bitcoina w badanym okresie obejmuje 3997 obserwacji. Średnia stopa zwrotu to około 0,14% dziennie, co sugeruje pewną dodatnią tendencję. Zmienność jest jednak bardzo wysoka - odchylenie standardowe sięga 3,6% dziennie. To wartość kilkukrotnie większa niż w przypadku głównych indeksów giełdowych.

Rozkład log-zwrotów wskazuje na częstą obecność znaczących zmian (leptokurtyczność). W 1% najgorszych dni spadki przekraczały -10%, a w 1% najlepszych wzrosty wynosiły ponad +10%. Skrajne obserwacje były jeszcze bardziej wyraziste: największy jednodniowy spadek wyniósł około -46% (marzec 2020), a największy wzrost +22,5%.

Takie wartości potwierdzają, że Bitcoin jest aktywem charakteryzującym się bardzo dużą zmiennością i ryzykiem występowania nagłych, ekstremalnych ruchów.

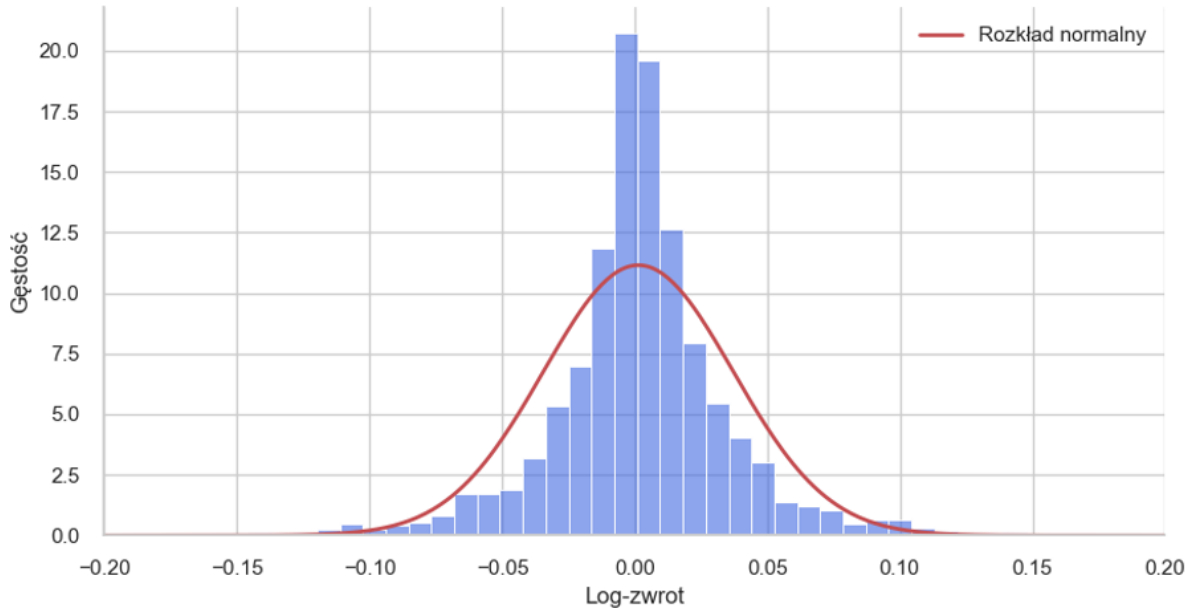

Wykres 3. Rozkład dziennych zwrotów logarytmicznych Bitcoina

Histogram dziennych log-zwrotów Bitcoina pokazuje silną koncentrację obserwacji wokół zera, co oznacza, że w większości dni zmiany cen były niewielkie. Jednocześnie rozkład nie jest zgodny z rozkładem normalnym – widoczny jest bardzo wąski i wysoki szczyt w centrum oraz grube ogony, co wskazuje na leptokurtyczność.

Test Jarque–Bera (Jarque i Bera, 1987) (statystyka ≈ 22 797, $p \ll 0{,}01$) statystycznie odrzuca hipotezę normalności rozkładu. Podobne wnioski daje test Shapiro–Wilka (Shapiro i Wilk, 1965) (statystyka = 0,93, $p \ll 0{,}01$), który wskazuje na istotne odchylenia od rozkładu gaussowskiego.

Dodatkowe miary rozkładu potwierdzają te wyniki. Skośność wynosi około –0,72, co oznacza lekką asymetrię w kierunku spadków – ujemne log-zwroty są częstsze lub bardziej nasilone niż dodatnie. Kurtoza na poziomie 11,6 znacznie przewyższa wartość dla rozkładu normalnego (3), co wskazuje na silną leptokurtyczność, czyli dużą częstość występowania obserwacji skrajnych.

Dodatkowo, test ADF (Augmented Dickey–Fuller) (Dickey i Fuller, 1979) zastosowany do dziennych log-zwrotów pozwala odrzucić hipotezę o obecności pierwiastka jednostkowego ($p \ll 0{,}01$), co potwierdza, że seria zwrotów jest stacjonarna. Jest to zgodne z teorią, według której poziomy cen są niestacjonarne, natomiast ich zwroty – stacjonarne.

Łącznie wyniki te dowodzą, że dzienne log-zwroty Bitcoina mają rozkład istotnie różniący się od normalnego: zdominowany przez dużą liczbę niewielkich zmian, ale z częstymi i silnymi epizodami skrajnych wahań. Obserwacje z mojej analizy (grube ogony, leptokurtoza, klasteryzacja zmienności) są spójne z ustaleniami literatury nt. Bitcoina (Nadarajah i Chu, 2017; Katsiampa, 2017; Phillip i in., 2018)

Dynamika zmienności

W analizie rynków finansowych istotne znaczenie ma nie tylko poziom stóp zwrotu, lecz także zmienność, która charakteryzuje skalę ryzyka inwestycji. W przypadku Bitcoina obserwuje się wyraźne okresy podwyższonej i obniżonej zmienności, co uzasadnia zastosowanie miar kroczących pozwalających na uchwycenie jej dynamiki w czasie.

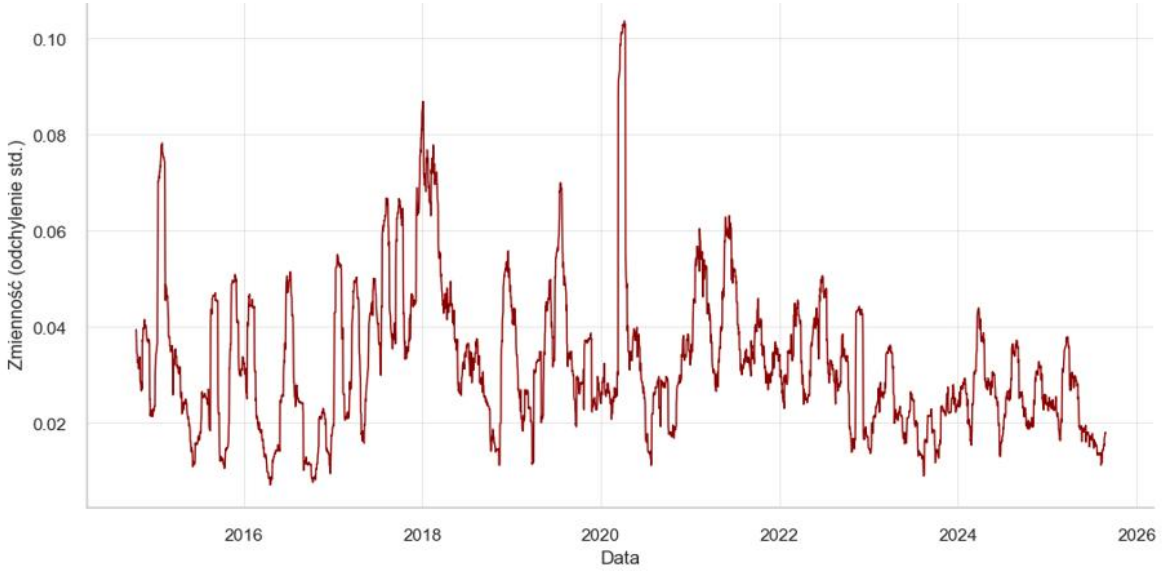

Wykres 4. Zmienność BTC w czasie (okno kroczące: 30 dni)

Na powyższym wykresie przedstawiono 30-dniową zmienność kroczącą log-zwrotów Bitcoina. Widać wyraźne okresy gwałtownych wahań, zwłaszcza w początkowych latach istnienia rynku oraz podczas nagłych szoków (np. w marcu 2020 r.). Jednocześnie zauważalny jest trend stopniowego wygładzania zmienności – w ostatnich latach fluktuacje stają się mniejsze, co może świadczyć o rosnącej dojrzałości rynku i większej płynności handlu.

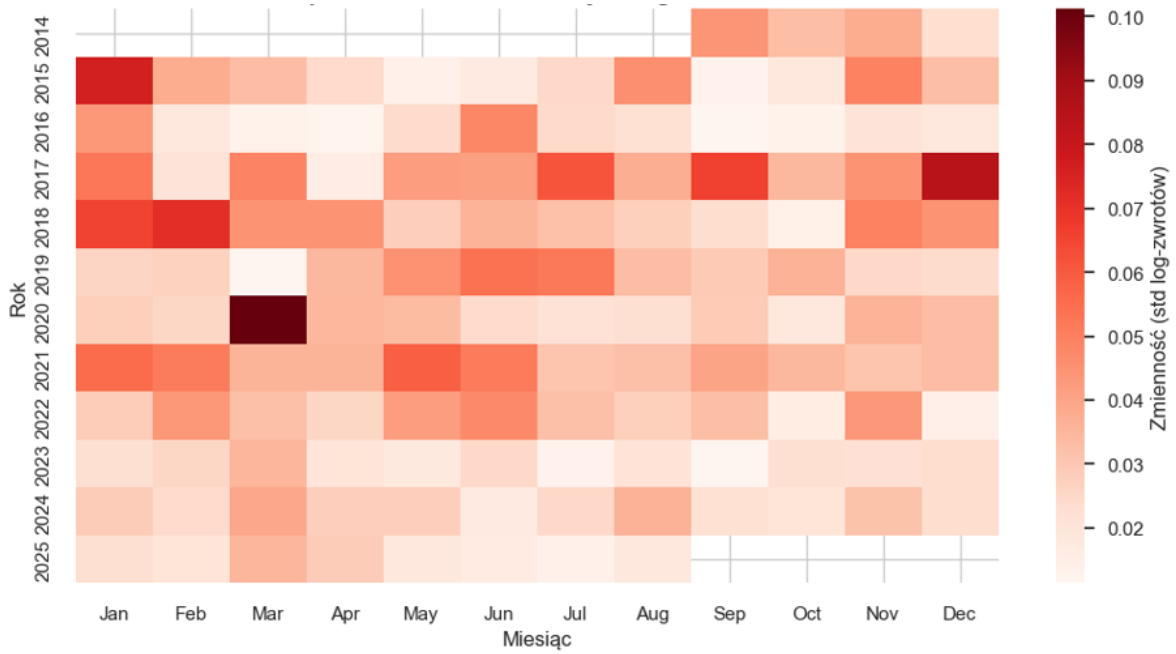

Wykres 5. Okresowa zmienność BTC w podziale na miesiąc i rok

Na pierwszym wykresie zaprezentowano zmienność miesięczną dziennych log-zwrotów Bitcoina w układzie rok–miesiąc. Widać wyraźnie, że w początkowych latach duża część miesięcy, zwłaszcza styczeń, charakteryzowała się podwyższoną zmiennością. Z kolei od 2023 roku wartości te wyraźnie się obniżyły, co można wiązać zarówno z rosnącą dojrzałością rynku, jak i ze wzrostem udziału inwestorów instytucjonalnych, zapewniających większą płynność

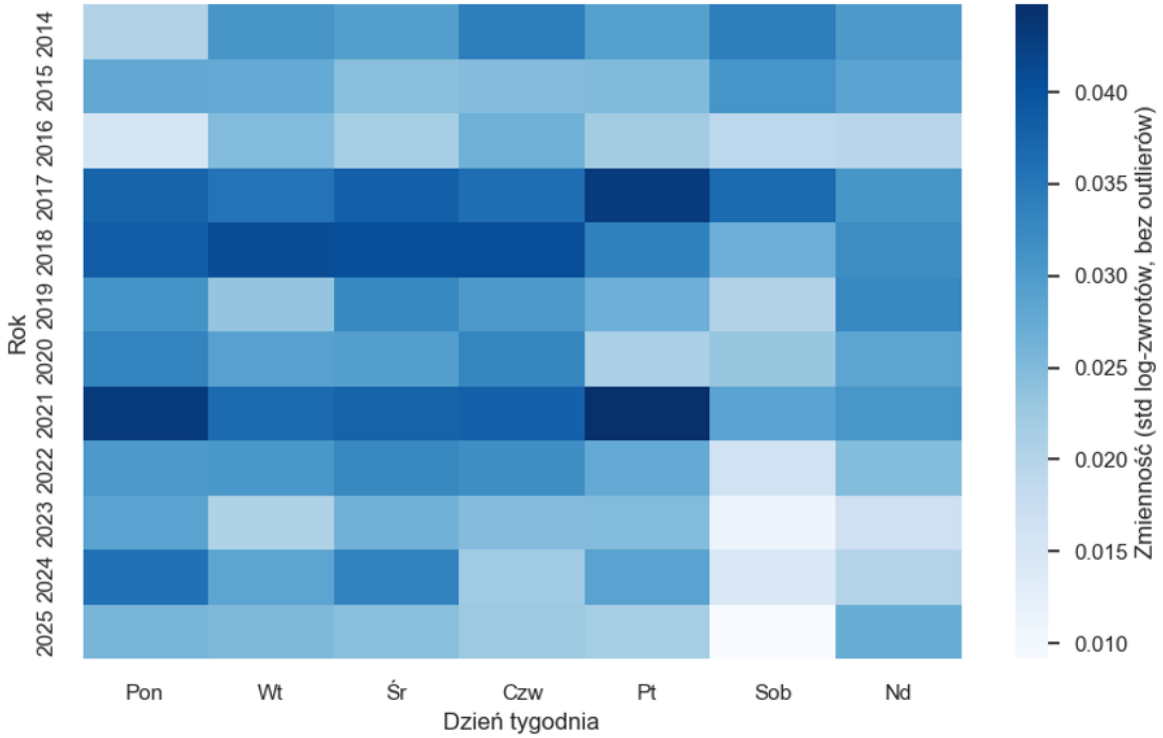

Wykres 6. Okresowa zmienność BTC w podziale na dzień tygodnia i rok

Kolejny wykres przedstawia zmienność w podziale na dni tygodnia, z rozbiciem na poszczególne lata. W obliczeniach zostały pominięte wartości odstające (1 i 99 percentyl), ponieważ pojedyncze ekstremalne zdarzenia mogłyby znacząco zaburzyć średni poziom zmienności. Widać, że w weekendy – szczególnie w soboty – zmienność była zwykle niższa niż w dni robocze, a efekt ten stał się wyraźniejszy w ostatnich latach. Może to odzwierciedlać fakt, że kluczowe impulsy cenowe coraz częściej pochodzą z klasycznych rynków finansowych, aktywnych jedynie od poniedziałku do piątku, co wzmacnia korelację Bitcoina z tradycyjnymi aktywami.

Wpływ makroekonomii i innych aktywów na cenę BTC

Bitcoin, pomimo swojej niezależnej genezy i często podkreślanego oderwania od tradycyjnych rynków finansowych, coraz wyraźniej reaguje na czynniki makroekonomiczne oraz zmiany w wycenach innych aktywów. W ostatnich latach szczególne znaczenie zaczęły mieć rentowności amerykańskich obligacji skarbowych (US10Y), ceny surowców takich jak złoto i ropa naftowa, polityka pieniężna Fed (stopy procentowe, agregaty pieniężne M2), a także kondycja rynków akcji mierzona indeksem S&P 500. Dodatkowo istotny wpływ mogą mieć indeks dolara (DXY), inflacja (CPI) czy miary awersji do ryzyka jak VIX. W niniejszej części pracy podjęta zostanie próba zbadania, w jakim stopniu czynniki te wpływają na wycenę BTC. Warto jednak

pamiętać, że choć znaczenie makroekonomii rośnie, Bitcoin wciąż podlega również wewnętrznym cyklom, szczególnie czteroletnim cyklom związanym z halvingiem, które od początku istnienia tego rynku odgrywają kluczową rolę w kształtowaniu trendów cenowych. Dodatkowo zgodnie z hipotezą efektywności rynku wpływ czynników makroekonomicznych może być widoczny w trendach długoterminowych, natomiast w skali dziennych zwrotów często bywa trudny do uchwycenia.

Rentowność 10-letnich obligacji skarbowych Stanów Zjednoczonych

Rentowność obligacji skarbowych Stanów Zjednoczonych o dziesięcioletnim terminie zapadalności (US10Y) jest jedną z kluczowych stóp procentowych w globalnej gospodarce. Stanowi punkt odniesienia dla wyceny wielu instrumentów finansowych, w tym kredytów, obligacji korporacyjnych czy aktywów ryzykownych. Wzrost rentowności oznacza wyższy koszt kapitału i atrakcyjniejszy zwrot z bezpiecznych obligacji, co często prowadzi do odpływu kapitału z rynków akcji i aktywów alternatywnych, w tym kryptowalut. Z kolei spadek US10Y zwykle sprzyja wzrostowi cen aktywów ryzykownych, ponieważ inwestorzy poszukują wyższych stóp zwrotu.

Wykres 7. Cena BTC i rentowność obligacji 10Y USA – porównanie w czasie

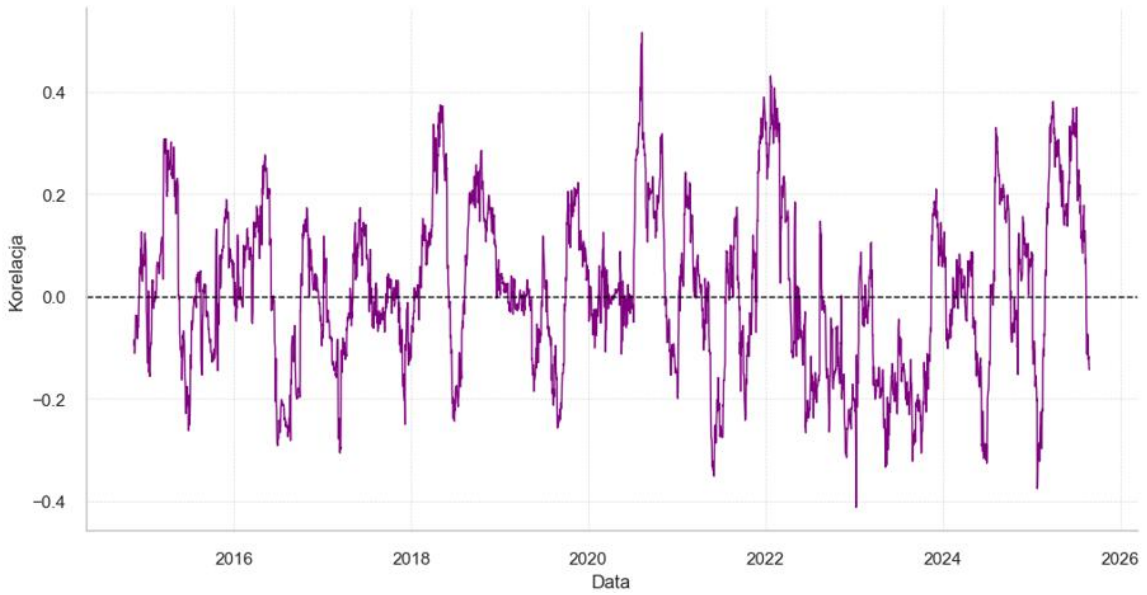

Wykres 8. Korelacja w czasie między BTC a US10Y (okno kroczące: 60 dni)

Na podstawie wykresów ceny Bitcoina i rentowności 10-letnich obligacji USA (US10Y) oraz kroczącej korelacji (60 dni) nie widać stałej zależności między tymi zmiennymi. Korelacja waha się od wartości dodatnich do ujemnych, co sugeruje, że relacja jest okresowa i silniejsza tylko w momentach wzrostu zmienności makroekonomicznej. Badania Wang i in. (2022) pokazują, że wzrost US10Y – szczególnie w fazach podwyżek stóp i oczekiwań inflacyjnych – wiąże się częściej ze spadkami BTC, choć z pewnym opóźnieniem.

Bloomberg Commodity Index

Indeks towarowy Bloomberg Commodity Index (BCOM) odzwierciedla zmiany cen w szerokim koszyku surowców, obejmującym m.in. energię, metale przemysłowe, metale szlachetne oraz produkty rolne. Jest on uznawany za istotny wskaźnik koniunktury gospodarczej. Wzrost wartości BCOM zwykle wiąże się z presją inflacyjną i rosnącym popytem na surowce, natomiast jego spadek może sygnalizować spowolnienie gospodarcze (Díaz i in. 2023). Ponieważ Bitcoin bywa postrzegany – zwłaszcza w ostatnich latach – jako potencjalne zabezpieczenie przed inflacją, zmiany BCOM mogą pośrednio oddziaływać na jego notowania.

Na podstawie poniższych wykresów widać, że w czasie pandemii i okresu wysokiej inflacji korelacja pomiędzy ceną Bitcoina a indeksem BCOM była wyraźnie dodatnia. Wzrost cen surowców i ogólna niepewność makroekonomiczna sprzyjały wówczas postrzeganiu BTC jako alternatywnego aktywa o cechach zbliżonych do surowców. Jednak od końca 2022 roku, kiedy inflacja zaczęła się obniżać, zależność ta wyraźnie osłabła. Bitcoin kontynuował wzrost

głównie dzięki własnym czynnikom, takim jak cykl czteroletnich halvingów czy oczekiwania związane z wprowadzeniem funduszy ETF opartych na spot BTC, podczas gdy BCOM pozostawał relatywnie stabilny w okolicach poziomu 100 punktów. To rozbieżne zachowanie doprowadziło do spadku korelacji, a w 2024 roku korelacja ta chwilowo przyjęła wartości ujemne.

Wykres 9. Cena BTC i Indeksu surowcowego BCOM – porównanie w czasie

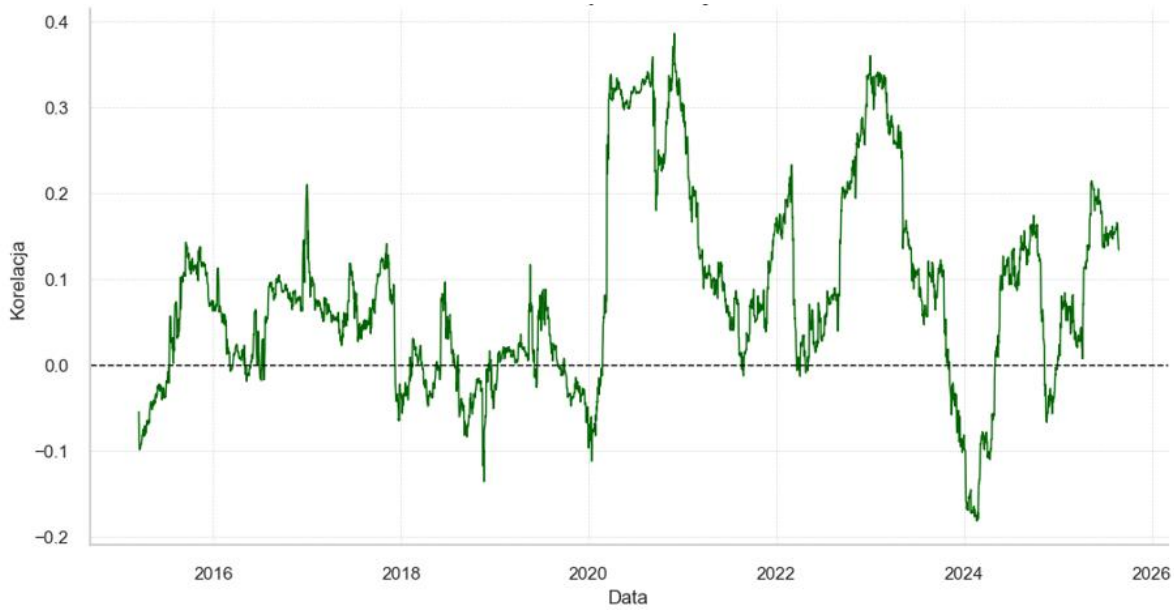

Wykres 10. Korelacja w czasie między BTC a BCOM (okno kroczące: 180 dni)

Wskaźnik Inflacji

CPI (Consumer Price Index) to wskaźnik inflacji mierzący zmiany średniego poziomu cen dóbr i usług konsumpcyjnych. W niniejszej pracy wykorzystano amerykański CPI, publikowany przez U.S. Bureau of Labor Statistics, który jest jednym z najważniejszych mierników sytuacji makroekonomicznej na świecie. Ma on kluczowe znaczenie dla decyzji Rezerwy Federalnej dotyczących stóp procentowych, a tym samym wpływa na globalne rynki finansowe, w tym na aktywa ryzykowne takie jak Bitcoin.

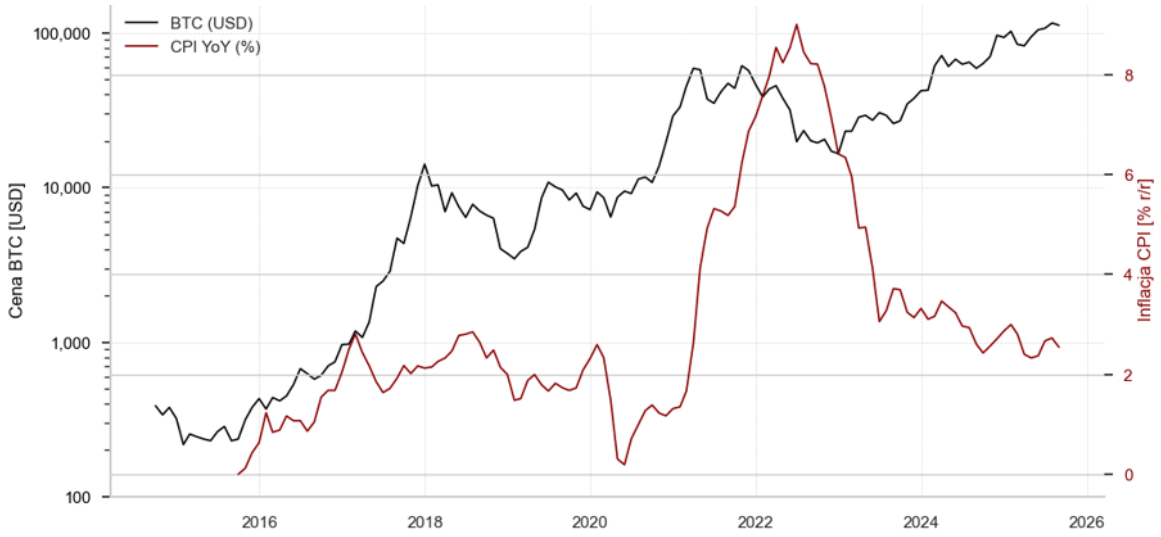

Wykres 11. Cena BTC i wskaźnika CPI (30-dniowe wygładzenie) – porównanie w czasie

Na pierwszym wykresie zależność pomiędzy ceną Bitcoina a dynamiką CPI przypomina tę obserwowaną przy indeksie BCOM – w okresach podwyższonej inflacji wzrosty CPI były powiązane z większą wrażliwością BTC

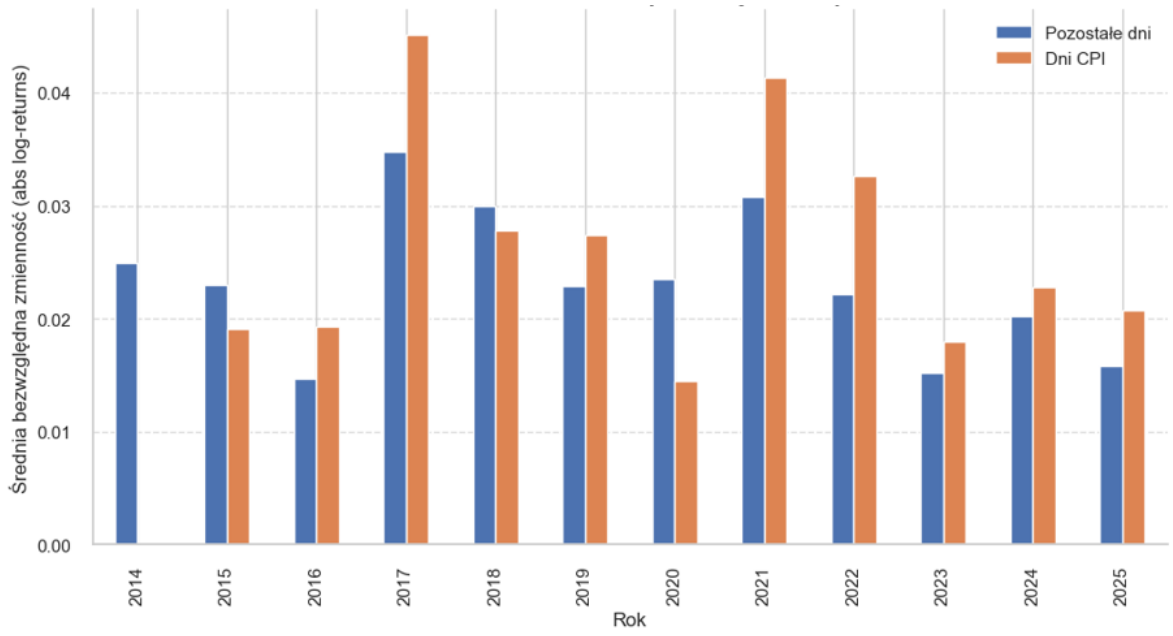

Wykres 12. Średnia dzienna zmienność Bitcoina w dniach publikacji CPI na tle pozostałych dni

Analiza zmienności wokół dat publikacji pokazuje natomiast, że od 2021 roku w dniu ogłaszania wskaźnika występowała wyraźnie wyższa zmienność w porównaniu do przeciętnych dni. Efekt ten szczególnie mocno uwidocznił się w latach 2021–2022, kiedy inflacja w USA osiągała najwyższe poziomy od dekad, a rynek kryptowalut reagował nerwowo na każdy sygnał mogący sugerować zmianę polityki monetarnej.

W literaturze wskazuje się, że Bitcoin w pewnych okresach pełnił rolę zabezpieczenia przed inflacją. Choi i in. (2022) zauważają, że *„Bitcoin zyskuje na wartości w odpowiedzi na szoki inflacyjne (lub związane z oczekiwaniami inflacyjnymi), co potwierdza jego rolę jako aktywa chroniącego przed inflacją, wskazywaną przez inwestorów”*

Stopy procentowe

Stopy procentowe w Stanach Zjednoczonych, ustalane przez Rezerwę Federalną, należą do najważniejszych czynników makroekonomicznych wpływających na rynki finansowe. Decyzje FOMC wyznaczają koszt pieniądza i kształtują oczekiwania co do przyszłej polityki monetarnej. W literaturze podkreśla się, że zmiany stóp oddziałują na wyceny aktywów ryzykownych – w tym także na kryptowaluty.

Bitcoin, mimo że początkowo postrzegany był jako aktywo niezależne od polityki banków centralnych, w ostatnich latach wykazuje coraz silniejsze powiązania z cyklem stóp

procentowych w USA. Ogłoszenia decyzji Fed często wiążą się ze wzrostem zmienności BTC, a niektóre badania wskazują na ujemną reakcję kursu na podwyżki stóp.

Wykres 13. Dzienna cena Bitcoina i stopa funduszy federalnych (Fed Funds Rate) – porównanie w czasie

Na wykresie widoczna jest zależność pomiędzy stopą Fed Funds a ceną Bitcoina. Okres po wybuchu pandemii COVID-19 charakteryzował się wyjątkowo niskimi stopami procentowymi, co zbiegło się z dynamicznym wzrostem ceny BTC do historycznych maksimów z końca 2021 roku. Następnie, począwszy od marca 2022 roku, Rezerwa Federalna rozpoczęła cykl agresywnych podwyżek stóp, co wywołało silne spadki na rynkach ryzykownych aktywów – również na Bitcoinie, którego cena znacząco się obniżyła.

Od 2023 roku Bitcoin ponownie zaczął rosnąć, głównie w wyniku własnych czynników wewnętrznych, takich jak zbliżający się halving czy decyzje dotyczące funduszy ETF opartych na BTC. Jednak skala tego wzrostu była mniejsza niż w poprzednich cyklach, co można częściowo tłumaczyć utrzymywaniem się wysokich stóp procentowych, ograniczających napływ kapitału spekulacyjnego.

Obserwacje te są zgodne z literaturą (Che i in, 2023), która wskazuje, że polityka pieniężna Rezerwy Federalnej oddziałuje na rynek kryptowalut również w szerszym ujęciu cyklicznym. Autorzy dowodzą, że zacieśnianie polityki Fed prowadzi do trwałego obniżenia tzw. „czynnika krypto”[4] poprzez kanał podejmowania ryzyka. Empirycznie pokazują, że wzrost stopy

[4] W badaniu Che i in. (2023) analizowany jest tzw. *czynnik krypto* – syntetyczna zmienna skonstruowana przy użyciu analizy czynnikowej z głównych kryptowalut, która odzwierciedla wspólny cykl tego rynku.

funduszy federalnych (FFR) o 1 punkt procentowy skutkuje spadkiem „czynnika krypto” o około 0,15 odchylenia standardowego, co podkreśla istotną wrażliwość rynku kryptowalut na kierunek zmian stóp procentowych w USA.

Z kolei reakcja Bitcoina na decyzje FOMC pokazuje, że dni ogłoszeń wiążą się ze wzrostem zmienności kursu. Jak zauważają Johansson i Vilhelmsson (2023, str. 16), „w minutach po ogłoszeniach FOMC następuje masowy i istotny wzrost wolumenu obrotu oraz zmienności”. Co więcej, to element zaskoczenia – nieoczekiwane zacieśnienie polityki monetarnej – odpowiada za najbardziej wyraźne spadki ceny BTC (Ma i in., 2022).

Cena złota

Bitcoin bywa określany mianem „cyfrowego złota”, bo – podobnie jak złoto – ma ograniczoną podaż i jest traktowany jako potencjalne zabezpieczenie przed inflacją. W praktyce jednak ich zachowania na rynku często się różnią. Złoto tradycyjnie pełni funkcję bezpiecznej przystani w okresach kryzysów finansowych, natomiast Bitcoin jest bardziej spekulacyjnym aktywem o wysokiej zmienności i własnych unikatowych cechach.

Wykres 14. Dzienna cena Bitcoina i cena złota – porównanie w czasie

Wykres 15. Korelacja w czasie między BTC a indeksem złota (okno kroczące: 180 dni)

Do 2020 roku korelacja pomiędzy Bitcoinem a złotem oscylowała między -0.1 i 0.1 - czyli, BTC i złoto zachowywały się niezależnie, bez wyraźnych wspólnych trendów. Po 2020 roku zaczęły pojawiać się okresy, w których korelacja rośnie, zwłaszcza w momentach kryzysów lub dużej niepewności ekonomicznej, takich jak pandemia COVID-19. Te skoki korelacji wydają się być reakcją na warunki makroekonomiczne - inflację, lęki o stabilność systemu finansowego, działania banków centralnych. Literatura to potwierdza: Terraza i in. (2024) pokazują większą dynamiczną współzależność BTC-złoto w trakcie COVID-19, a w badaniu (Panyagometh, 2024) podkreślono, że zarówno pandemia, jak i normalizacja polityki monetarnej od 2022 r. zwiększyły korelację. Jednak nawet w tych okresach korelacja nie osiąga zwykle ekstremalnych wartości; pozostaje umiarkowana. To sugeruje, że mimo iż złoto i Bitcoin mogą czasem reagować podobnie na duże zewnętrzne szoki, ich podstawowe mechanizmy i czynniki wpływu są wciąż różne.

Podaż pieniądza M2

Agregat M2 jest jedną z najczęściej stosowanych miar podaży pieniądza w gospodarce. Obejmuje on gotówkę w obiegu (monety i banknoty), depozyty na żądanie (rachunki bieżące), a także depozyty terminowe o wysokiej płynności oraz inne łatwo wymienialne formy pieniądza. W porównaniu do agregatu M1, który uwzględnia wyłącznie najbardziej płynne formy, M2 dostarcza szerszej perspektywy ilości pieniądza dostępnego w systemie finansowym.

Wzrost podaży pieniądza M2 zwykle odzwierciedla ekspansywną politykę monetarną banku centralnego i może być związany z rosnącą inflacją oraz większą skłonnością do podejmowania ryzyka na rynkach finansowych. Z kolei spowolnienie tempa wzrostu M2 sygnalizuje zaostrzenie warunków monetarnych, co ogranicza płynność w gospodarce i bywa czynnikiem hamującym wyceny aktywów ryzykownych, w tym kryptowalut.

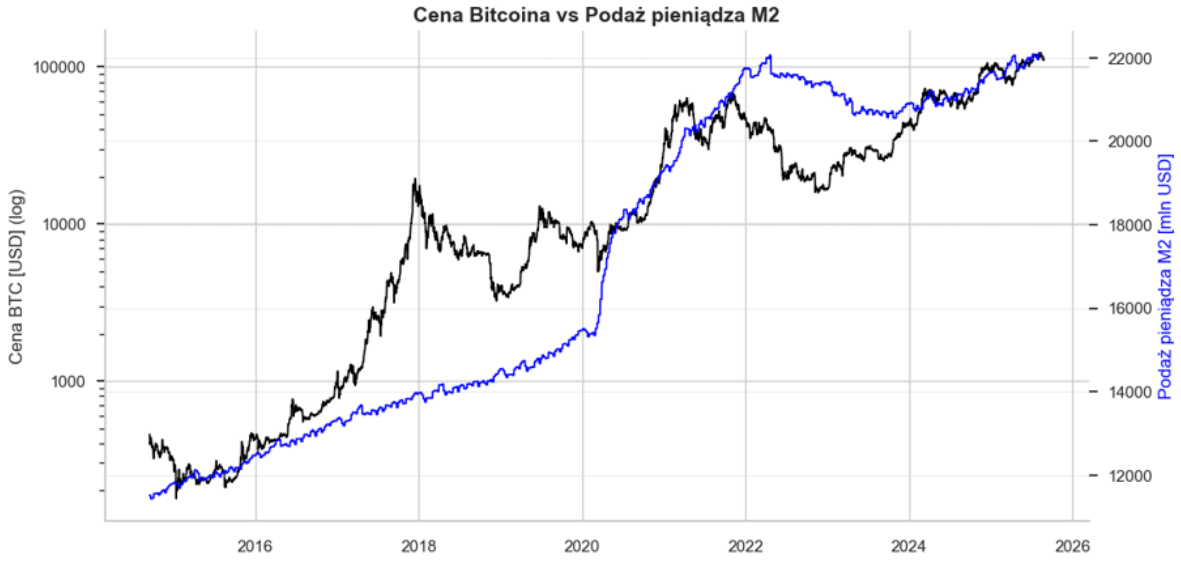

Wykres 16. Dzienna cena BTC i podaż pieniądza M2 – porównanie w czasie

Do wybuchu pandemii COVID-19 nie widać wyraźnej zależności pomiędzy dynamiką podaży pieniądza M2 a ceną Bitcoina – oba szeregi rozwijały się w dużej mierze niezależnie. Sytuacja zmieniła się w 2020 roku: skokowy wzrost M2 związany z ekspansywną polityką monetarną zbiegł się z gwałtownym boomem na rynku BTC. W kolejnych latach wyhamowanie tempa wzrostu M2 pokrywało się z okresem spowolnienia i korekt na Bitcoinie, co sugeruje rosnącą wrażliwość kryptowaluty na płynność monetarną. Widać również, że Bitcoin zaczął rosnąć przed zatwierdzeniem ETF-ów, mimo że M2 pozostawało w stagnacji – jednak późniejsze odbicie podaży pieniądza ponownie zbiegło się z umocnieniem BTC. Całość obrazu wskazuje, że od 2020 roku polityka monetarna (mierzona przez M2) stała się istotnym tłem dla cykli Bitcoina, choć relacja nie jest liniowa ani w pełni synchroniczna.

Siła Dolara Amerykańskiego

Dolar (indeks DXY) pełni kluczową rolę w wycenie Bitcoina, ponieważ BTC jest denominowany w USD. W praktyce osłabienie dolara zwykle sprzyja aktywom ryzykownym, w tym kryptowalutom, gdyż inwestorzy chętniej szukają alternatywnych sposobów lokowania kapitału. Z kolei silny dolar oznacza odpływ kapitału do „bezpiecznej przystani", co

historycznie wiązało się z presją spadkową na Bitcoina. Dlatego DXY jest traktowany jako pośredni predyktor sentymentu inwestorów wobec BTC i innych aktywów ryzykownych.

Wykres 17. Dzienna cena BTC i indeks dolara – porównanie w czasie

Wykres 18. Korelacja w czasie między BTC a indeksem dolara (okno kroczące: 180 dni)

Na wykresach widać wyraźną ujemną zależność pomiędzy kursem Bitcoina a indeksem dolara (DXY), szczególnie po 2020 roku. Umocnienie dolara często wiązało się z osłabieniem ceny BTC, podczas gdy lokalne dołki DXY zbiegały się w czasie z lokalnymi szczytami Bitcoina. Analogicznie – gdy dolar osiągał lokalne maksima, notowania BTC znajdowały się w pobliżu lokalnych minimów. Taka odwrotna relacja jest spójna z obserwacjami z rynków finansowych,

gdzie mocny dolar ogranicza napływ kapitału do aktywów ryzykownych, a jego osłabienie sprzyja wzrostom cen takich aktywów jak Bitcoin (Avdijev i in., 2019; Lin i in., 2025)

Indeks S&P 500

Indeks S&P 500 (SPX) jest najważniejszym barometrem koniunktury na amerykańskim rynku akcji i jednym z kluczowych wskaźników globalnego sentymentu inwestycyjnego. Jego dynamika odzwierciedla apetyt na ryzyko – gdy inwestorzy chętniej angażują kapitał w akcje, zwykle rosną też inne aktywa ryzykowne, w tym Bitcoin. W ostatnich latach, szczególnie po pandemii COVID-19, zależność między SPX a BTC stała się wyraźniejsza: Bitcoin często podąża za nastrojami z rynku akcji, podczas gdy lokalne spadki indeksu bywały zapowiedzią osłabienia również w kryptowalutach (Kalamen i in., 2024). Choć zdarzają się okresy, w których BTC reaguje szybciej na zmiany sentymentu, to w ujęciu ogólnym można mówić o tym, że kurs Bitcoina w dużej mierze śledzi koniunkturę na rynku akcji reprezentowaną przez indeks S&P 500.

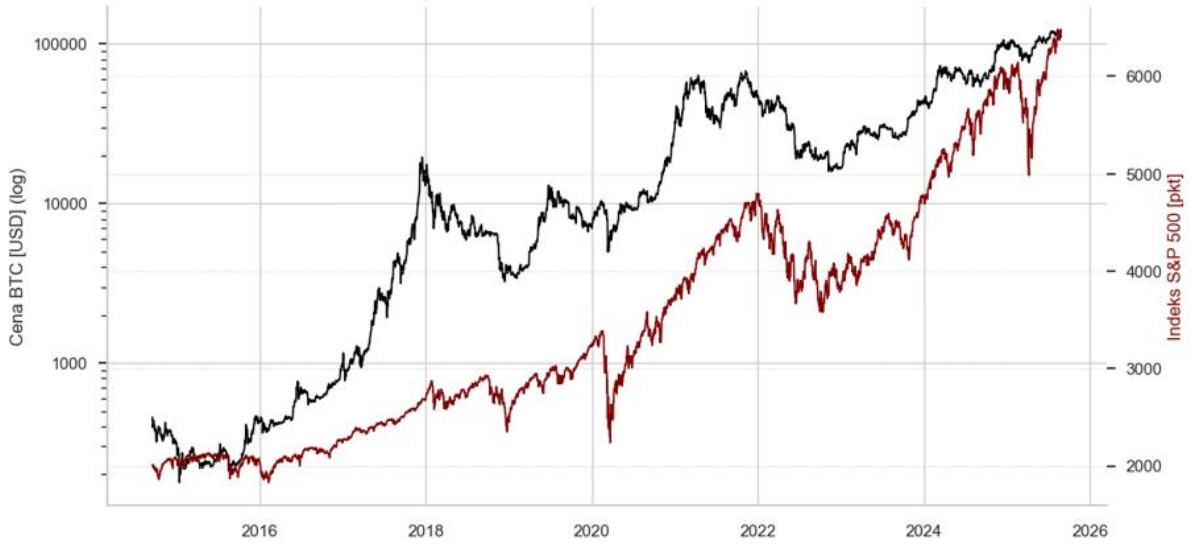

Wykres 19. Dzienna cena BTC i indeks akcji S&P500 – porównanie w czasie

Na wykresie widać, że Bitcoin charakteryzuje się znacznie większą zmiennością niż indeks S&P 500 – jego spadki są głębsze, a wzrosty bardziej dynamiczne. W ostatnim czasie ta różnica w zmienności zaczęła się zmniejszać, co może świadczyć o dojrzewaniu rynku Bitcoina i jego stopniowym upodabnianiu się pod względem stabilności do tradycyjnych aktywów, takich jak indeks S&P 500. Ogólnie kierunki ruchów obu instrumentów są zbliżone, a ich współzależność stała się szczególnie wyraźna po pandemii COVID-19.

Na wykresie 2 widać, że do 2020 roku korelacja między BTC a S&P 500 była niska i często nieistotna. Jednak w trakcie pandemii wzrosła gwałtownie, osiągając wartości rzędu 0,6, a w szczycie 2023 roku przekroczyła nawet 0,7. Od tego czasu korelacja utrzymuje się na dodatnich poziomach, co wskazuje na istotne powiązanie nastrojów na rynku akcji i kryptowalut. Sporadyczne spadki korelacji w okolice zera są krótkotrwałe i nie zmieniają ogólnego obrazu zależności.

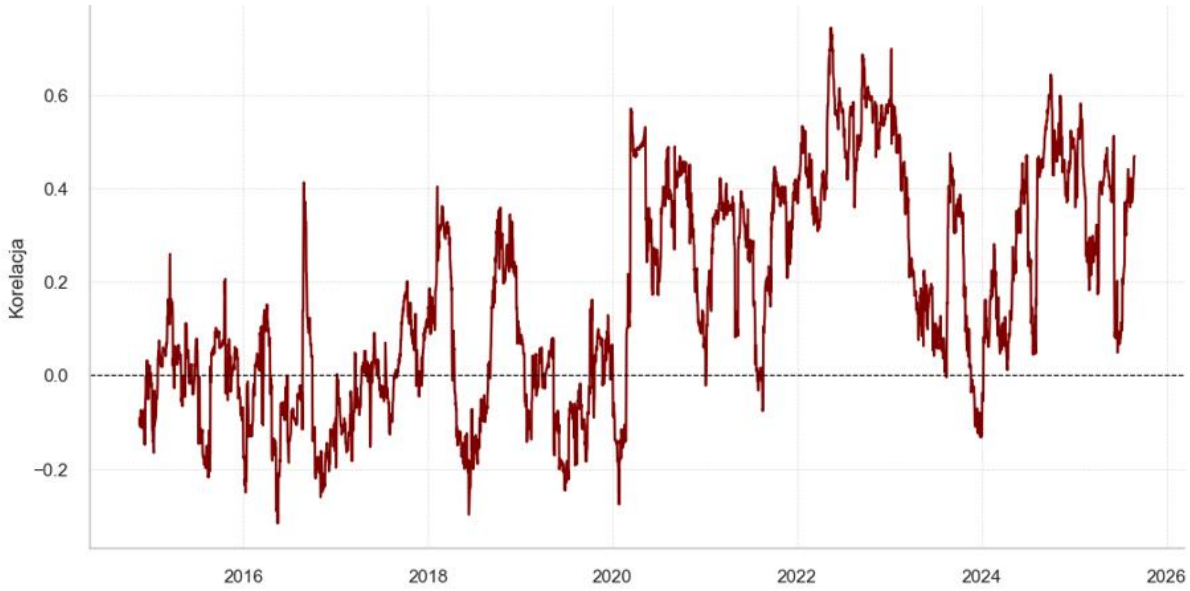

Wykres 20. Korelacja w czasie między BTC a indeksem S&P500 (okno kroczące: 60 dni)

VIX

Indeks VIX, zwany także „indeksem strachu", mierzy oczekiwaną zmienność na rynku akcji (oparty na opcjach na S&P 500). Jego wzrosty zazwyczaj wiążą się z rosnącą awersją do ryzyka i spadkami na rynkach akcji, a także odpływem kapitału z bardziej ryzykownych aktywów – w tym kryptowalut.

Badania empiryczne wskazują na ujemną zależność pomiędzy VIX a Bitcoinem – gdy VIX rośnie, ceny BTC częściej spadają (Wang i in., 2022). Co więcej, ta korelacja nasila się w okresach kryzysowych (np. pandemia COVID-19, kryzysy płynności). Oznacza to, że Bitcoin nie pełni roli bezpiecznej przystani w momentach paniki rynkowej, lecz zachowuje się jak klasyczne aktywo ryzykowne. W praktyce lokalne skoki VIX często wyznaczały dołki na BTC, a uspokojenie indeksu sprzyjało jego odbiciom.

Wykres 21. Dzienna cena BTC i indeks VIX – porównanie w czasie

Na pierwszym wykresie widać, że duże skoki indeksu VIX często pokrywały się z gwałtownymi spadkami ceny Bitcoina. Potwierdza to, że BTC reaguje na wzrost awersji do ryzyka podobnie jak inne aktywa spekulacyjne.

Wykres 22. Korelacja w czasie między BTC a VIX (okno kroczące: 180 dni)

Korelacja między VIX a Bitcoinem przed 2020 rokiem była niska i wskazywała, że BTC funkcjonował w dużej mierze niezależnie. Po pandemii COVID-19 zależność wyraźnie się nasiliła – współczynnik korelacji utrzymuje się na ujemnym poziomie (od –0.2 do –0.5), co wskazuje na trwałą odwrotną relację: wzrost VIX zwykle wiąże się ze spadkiem BTC.

Podsumowanie

Analiza eksploracyjna pokazała, że makroekonomiczne czynniki otoczenia mają coraz większe znaczenie dla kształtowania się ceny Bitcoina – szczególnie po 2020 roku, kiedy to kryptowaluty zaczęły być traktowane szerzej jako element portfeli inwestycyjnych, a nie tylko niszowe aktywa spekulacyjne. Warto jednak podkreślić, że korelacja nie implikuje przyczynowości, a wpływ czynników makroekonomicznych na dzienne zmiany jest zazwyczaj ograniczony

Cykle 4 letnie Bitcoina

Jak widać na poniższym wykresie, cykle cenowe Bitcoina są silnie powiązane zarówno z datami halvingów, jak i momentami ukształtowania się rynkowych dołków. We wszystkich obserwowanych przypadkach po halvingu następował dynamiczny wzrost wartości BTC, co potwierdza hipotezę o wpływie ograniczania podaży na stronę podażowo-popytową rynku. Analiza liczby dni pomiędzy poszczególnymi punktami zwrotnymi wskazuje dodatkowo na pewną regularność: odstępy czasowe pomiędzy dołkiem, halvingiem a kolejnym szczytem cenowym pozostają zbliżone – między 1050 a 1100 dni od dna rynku do osiągnięcia nowego maksimum. Sugeruje to, że rynek Bitcoina podlega powtarzalnym cyklom, w których halving pełni rolę katalizatora zmiany trendu. Warto również zauważyć, że choć każdy cykl przynosił nowe szczyty, dynamika wzrostów z cyklu na cykl maleje, co może być konsekwencją rosnącej kapitalizacji oraz silniejszych powiązań z tradycyjnymi rynkami finansowymi.

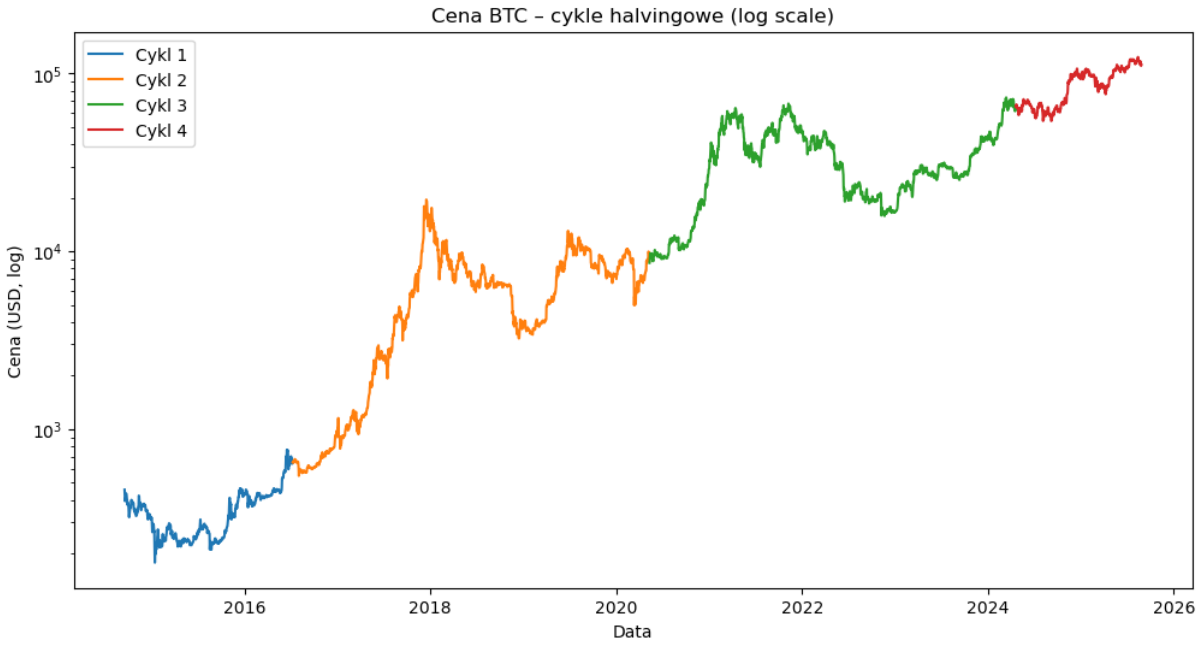

Wykres 23. Wykres cenowy BTC podzielony na cykle (każdy kolor oznacza nowy cokl począwszy od halvingu)

3.3 Opis zastosowanych modeli predykcyjnych

3.3.1 ARIMA jako model bazowy

Model ARIMA (*Autoregressive Integrated Moving Average*) jest klasycznym narzędziem do modelowania i prognozowania szeregów czasowych (Box i Jenkins, 2008). Oznaczenie ARIMA (p, d, q) odnosi się do trzech komponentów:

AR (autoregressive, p) – część autoregresyjna, w której bieżąca wartość szeregu zależy od liniowej kombinacji *p* przeszłych wartości. Umożliwia to modelowi uchwycenie autokorelacji:

$$y_t = c + \phi_1 y_{\{t-1\}} + \phi_2 y_{\{t-2\}} + \dots + \phi_p y_{\{t-p\}} + \epsilon_t$$

gdzie:

y_t – bieżąca wartość szeregu,

c – stała (intercept),

ϕ_i – współczynniki autoregresyjne (wpływ przeszłych wartości),

p – rząd autoregresji,

ϵ_t – składnik losowy (white noise).

I (integrated, d) – część zróżnicowana, która polega na odejmowaniu wartości opóźnionych w celu uzyskania stacjonarności szeregu. Jeśli dane mają trend lub niestabilną wariancję, zastosowanie różnicowania pozwala je ustabilizować. Parametr d oznacza liczbę zastosowanych różnicowań. Gdy d=0 model działa na oryginalnym szeregu bez transformacji.

MA (moving average, q) – część średniej ruchomej, w której bieżąca wartość zależy od liniowej kombinacji q wcześniejszych składników błędu. Dzięki temu model może uchwycić wpływ niespodziewanych szoków z przeszłości na obecną wartość szeregu:

$$y_t = \theta_1 \epsilon_{\{t-1\}} + \theta_2 \epsilon_{\{t-2\}} + \dots + \theta_q \epsilon_{\{t-q\}} + \epsilon_t$$

gdzie:

y_t – bieżąca wartość szeregu czasowego,

θ_j – współczynniki części średniej ruchomej (MA), określające wpływ wcześniejszych błędów na bieżącą wartość,

ϵ_t – bieżący składnik losowy (white noise),

$\epsilon_{\{t-j\}}$ – składniki losowe z przeszłości (błędy prognozy)

Model ARIMA łączy wszystkie trzy komponenty, co pozwala na jednoczesne uchwycenie autokorelacji, stabilizację niestacjonarnego szeregu i uwzględnienie wpływu wcześniejszych błędów prognozy.

W analizie zastosowano procedurę automatycznego doboru parametrów (*auto_arima*), która na podstawie RMSE wskazała jako najlepiej dopasowany model ARIMA (0,0,0) z wyrazem wolnym. Oznacza to, że logarytmiczne zwroty Bitcoina można opisać jako szum biały z niezerową średnią (stała).

W praktyce prognoza kolejnej wartości w takim modelu sprowadza się do średniej szeregu, a dodatkowe komponenty AR czy MA nie poprawiają dopasowania. Jest to ważny wynik, ponieważ ARIMA (0,0,0) stanowi minimalny benchmark – wyznacza punkt odniesienia, względem, którego można ocenić wartość dodaną bardziej złożonych metod, takich jak sieci neuronowe. W literaturze wielokrotnie wskazywano, że log-zwroty aktywów finansowych w krótkim horyzoncie często zachowują się jak proces losowy, co potwierdza hipotezę rynku efektywnego (np. Cont, 2001).

3.3.2 LSTM jako główny model predykcji

Rekurencyjne sieci neuronowe (RNN) są naturalnym wyborem do analizy szeregów czasowych, jednak ich klasyczna wersja cierpi na problem zanikającego i eksplodującego gradientu. Rozszerzeniem RNN są sieci LSTM (Long Short-Term Memory), które dzięki wbudowanym mechanizmom bramek potrafią przechowywać istotne informacje przez dłuższe okresy oraz usuwać te mniej istotne (Hochreiter i Schmidhuber, 1997). Architektura komórki LSTM przedstawiona na poniższym rysunku odpowiada wersji z bramką zapominania (Gers i in., 2000) i składa się z trzech bramek sterujących przepływem informacji: zapominania, wejściowej i wyjściowej:

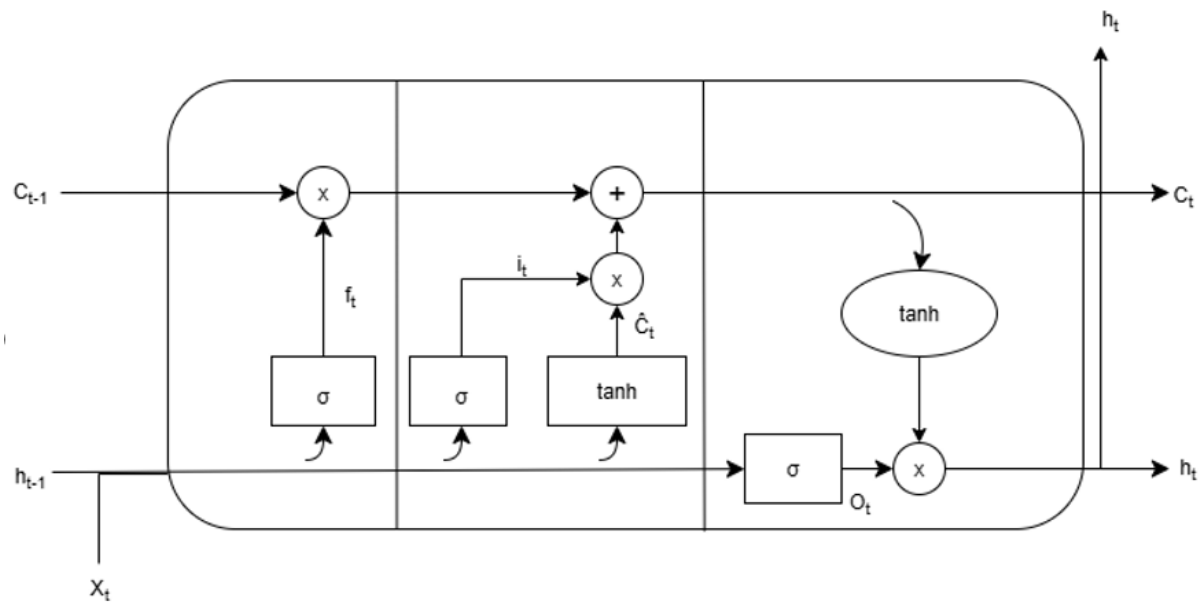

Wykres 24. Schemat działania modelu LSTM (opracowanie własne na podstawie literatury: Gers i in., 2000)

Bramka zapominania (f_t)

Pierwszym etapem w komórce LSTM jest bramka zapominania, która decyduje, które informacje przechowywane w stanie pamięci z poprzedniego kroku (C_{t-1}) należy zachować, a które odrzucić. Na wejściu otrzymuje ona poprzedni stan ukryty (h_{t-1}) oraz bieżące dane (x_t). Funkcja aktywacji sigmoid zwraca wartości z przedziału [0,1], które pełnią rolę filtra: wartości bliskie 0 oznaczają odrzucenie, a bliskie 1 – zachowanie danej informacji. W ten sposób f_t punktowo modyfikuje C_{t-1}, „czyszcząc" nieistotne elementy.

Bramka wejściowa (i_t) i proponowany stan pamięci ($\widetilde{C}_t$)

Kolejny etap dotyczy aktualizacji pamięci o nowe informacje. Bramka wejściowa generuje wektor filtrujący (i_t) na podstawie h_{t-1} i x_t, ponownie z użyciem funkcji sigmoid. Równocześnie tworzony jest proponowany stan pamięci $\tilde{C}_t$ z wykorzystaniem funkcji tanh, co umożliwia uwzględnianie zarówno dodatnich, jak i ujemnych wpływów nowych danych. Dopiero iloczyn $i_t \odot \tilde{C}_t$ decyduje, które elementy nowej informacji zostaną faktycznie dodane do pamięci. Ostateczny stan pamięci to kombinacja części zachowanej ze starego stanu i nowych, istotnych danych:

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t$$

Bramka wyjściowa (0_t)

Ostatnim elementem komórki jest bramka wyjściowa, odpowiedzialna za wygenerowanie stanu ukrytego (h_t) Na podstawie h_{t-1} i x_t tworzy ona wektor filtrujący (o_t) z wartościami w [0,1]. Równocześnie nowy stan pamięci (C_t) zostaje przekształcony przez funkcję $tanh$, co ogranicza jego wartości do [−1,1]. Dopiero wynik tego przekształcenia zostaje pomnożony punktowo przez 0_t, co daje końcowy stan ukryty:

$$h_t = o_t \odot tanh(C_t)$$

Stan ukryty jest zarówno wyjściem modelu w chwili t, jak i sygnałem wejściowym do kolejnej komórki. Warto podkreślić, że C_t pełni rolę pamięci długoterminowej, natomiast h_t odpowiada za pamięć krótkoterminową. Dzięki temu LSTM jest w stanie jednocześnie przechowywać ogólny kontekst sekwencji i reagować na bieżące dane. Komórki LSTM są łańcuchowo połączone, co oznacza, że sieć jest w stanie analizować sekwencje wielu kroków czasowych poprzez tzw. rozwijanie w czasie. Pozwala to modelowi uczyć się zarówno lokalnych, jak i odległych zależności w szeregach czasowych, co odróżnia go od klasycznych RNN

Strojenie hiperparametrów

Strojenie hiperparametrów przeprowadzono na pierwszym modelu z zestawem zmiennych objaśniających obejmujących wolumen (model 2). Dla tego modelu testowano różne kombinacje parametrów sieci LSTM, a ich skuteczność oceniano na podstawie wartości błędu RMSE obliczanego na zbiorze walidacyjnym. Proces strojenia przeprowadzono metodą przeszukiwania siatką (grid search), testując wszystkie kombinacje wybranych wartości hiperparametrów. Po wyłonieniu najlepszego zestawu ustawień te same hiperparametry zastosowano we wszystkich pozostałych wariantach modeli. Część hiperparametrów została przetestowana, a część — ze względu na ograniczone moce obliczeniowe — przyjęto odgórnie.

Hiperparametr	**Opis**	**Zakres testowanych wartości**	**Wartość końcowa**
Liczba jednostek LSTM	Liczba neuronów w warstwie LSTM	{32, 64}	64
Dropout	Odsetek dezaktywowanych neuronów w trakcie uczenia	{0.1, 0.3}	0.3
Współczynnik uczenia	Tempo aktualizacji wag w procesie uczenia	{0.0005, 0.001}	0.001
Długość okna czasowego (lookback)	Liczba dni wykorzystywanych jako dane wejściowe	{30, 60}	60

Wielkość partii (batch size)	Liczba próbek przetwarzanych w jednym kroku uczenia	Przyjęta z góry	64
Liczba warstw LSTM	Liczba warstw rekurencyjnych w sieci	Przyjęta z góry	1
Funkcja straty	Miara błędu predykcji	Przyjęta z góry	MSE
Optymalizator	Algorytm minimalizacji funkcji błędu	Przyjęta z góry	Adam
Liczba epok (maks.)	Maksymalna liczba przejść przez dane uczące	Przyjęta z góry	200
Mechanizm wczesnego zatrzymania	Kryterium przerwania uczenia przy braku poprawy błędu	Przyjęta z góry	patience = 10
Ziarno losowe (seed)	Wartość inicjalizująca losowość w uczeniu	Przyjęta z góry	42

Tabela 3. Hiperparametry modelu LSTM

Podsumowanie

W odróżnieniu od klasycznych modeli liniowych, takich jak ARIMA, LSTM może uchwycić nieliniowe zależności oraz interakcje pomiędzy danymi historycznymi. Czyni go to szczególnie przydatnym w przypadku szeregów finansowych, które często charakteryzują się dużą zmiennością, obecnością efektów nieliniowych i złożoną dynamiką. Dzięki mechanizmowi pamięci długoterminowej, LSTM lepiej radzi sobie także z wykrywaniem zależności w dłuższych horyzontach czasowych, gdzie modele tradycyjne zawodzą.

3.3.3 Modele z dodatkowymi zmiennymi

Modele LSTM mogą być wzbogacane o dodatkowe zmienne objaśniając, które pozwalają uchwycić czynniki kształtujące cenę Bitcoina, a których nie da się odczytać wyłącznie z samej serii cenowej. Zmienna docelowa (log-zwrot BTC) odzwierciedla bowiem nie tylko wewnętrzną dynamikę kursu, ale także wpływ czynników rynkowych, fundamentalnych czy makroekonomicznych. Uwzględnienie dodatkowych cech umożliwia modelowi uchwycenie bardziej złożonych, często nieliniowych zależności oraz może prowadzić do poprawy jakości prognoz.

Bloki zmiennych

Aby ocenić, które rodzaje zmiennych są najbardziej informatywne, modele zostały pogrupowane w bloki:

- Model 1: log-zwrot BTC
- Model 2: zmienne wolumenowe,
- Model 3: zmienne oparte o świece OHLC,
- Model 4: zaawansowane wskaźniki zmienności i momentum,
- Model 5: klasyczne wskaźniki analizy technicznej,
- Model 6: zmienne on-chain i fundamentalne specyficzne dla Bitcoina,
- Model 7: zmienne makroekonomiczne.

Takie podejście pozwala sprawdzić nie tylko, które konkretne zmienne poprawiają model, ale też które rodzaje informacji (techniczne, wolumenowe, fundamentalne, makroekonomiczne) są najważniejsze dla prognozowania BTC.

Początkowe zmienne w modelach

Każdy model został zbudowany w oparciu o inny zestaw zmiennych objaśniających, których początkowe konfiguracje przedstawiono poniżej.

Model 2 – zmienne wolumenowe

W literaturze podkreśla się znaczenie wolumenu w analizie Bitcoina. Badania wskazują, że aktywność handlowa może zawierać informacje o przyszłych zwrotach w ujęciu dziennym (Hau i in., 2021). Zmienne takie jak OBV czy relatywne miary wolumenu są klasycznymi wskaźnikami potwierdzającymi trend (Murphy, 1999), natomiast miary zmienności wolumenu oraz jego transformacje (np. logarytmiczna) pomagają uchwycić nieliniowe efekty i anomalie (De Luca i Montanino, 2025). Dzięki temu blok wolumenowy pozwala modelowi LSTM lepiej oddać związek pomiędzy aktywnością rynku a zmianami ceny BTC.

Nazwa zmiennej	**Opis**	**Ostateczna**
Wolumen (poziom)	Ogólna aktywność na rynku – ile BTC przeszło przez rynek w danym dniu.	Nie
Log wolumenu	Transformacja logarytmiczna, redukuje skośność rozkładu wolumenu.	Tak

Zmiana % wolumenu	Miara dynamiki aktywności handlu (dzień do dnia).	Nie
Średnia krocząca wolumenu (20 dni)	„Norma” aktywności w krótkim okresie, sygnał trendu.	Nie
Zmienność wolumenu (20 dni)	Jak bardzo zmienia się aktywność w krótkim oknie.	Nie
Z-score wolumenu (20 dni)	Miara odchyleń wolumenu względem średniej w oknie (anomalia).	Nie
On-Balance Volume (OBV)	Przepływ wolumenu ważony kierunkiem ceny – potwierdzenie trendu.	Tak
Turnover vs średnia (30 dni)	Relatywna aktywność względem „normalnego” poziomu w dłuższym oknie.	Nie

Załącznik 1. Zmienne wolumenowe wykorzystane w modelach LSTM (opracowanie własne)

Model 3 – zmienne świecowe

Cechy świecowe (OHLC) są fundamentem klasycznej analizy technicznej, szeroko opisywanej m.in. przez *Murphy (1999)* oraz nowsze badania dotyczące kryptowalut (Uzun i in., 2024). Wskaźniki takie jak HL log-range czy True Range są dobrze znanymi miernikami zmienności i używane są również w konstrukcji bardziej złożonych wskaźników (np. ATR). Z kolei Body log i CLV pomagają uchwycić równowagę pomiędzy popytem a podażą w danym dniu, co według literatury może nieść sygnały prognostyczne. W kontekście niniejszej pracy warto zauważyć, że rozszerzenie modelu o cechy świecowe może pomóc uchwycić krótkoterminowe formacje i anomalie, które nie są widoczne w samych zwrotach.

Nazwa zmiennej	**Opis**	**Ostateczna**
HL log-range	Logarytmiczna różnica między ceną maksymalną i minimalną (miara zmienności proporcjonalnej).	Tak
True Range	Największy dzienny ruch uwzględniający luki (volatility proxy).	Nie
Body log	Logarytm różnicy między ceną zamknięcia a otwarcia (kierunek i siła dziennej świecy).	Nie
Close Location Value (CLV)	Pozycja ceny zamknięcia względem całej świecy (popyt vs podaż).	Nie

Upper Wick Ratio	Proporcja górnego knota do całej świecy (presja podaży).	Nie
Lower Wick Ratio	Proporcja dolnego knota do całej świecy (presja popytu).	Tak
Gap Open (log)	Luka pomiędzy wczorajszym zamknięciem a dzisiejszym otwarciem (nastroje rynkowe).	Nie

Tabela 4. Zmienne świecowe wykorzystane w modelach LSTM (opracowanie własne)

Model 4 – Zmienne momentum i zmienności

Blok zmiennych w modelu 4 skupia się na klasycznych miernikach momentum i zmienności, które są podstawą wielu strategii inwestycyjnych. Zmienna momentum odzwierciedla efekt opisany w literaturze – np. *Caporale i Plastun (2020)* wskazują na silne krótkoterminowe efekty momentum w BTC i innych kryptowalutach. Z kolei miary zmienności, takie jak rolling volatility czy Parkinson RV, pozwalają uchwycić ryzyko rynkowe lepiej niż tradycyjne odchylenie standardowe (Parkinson, 1980). Volatility Ratio umożliwia identyfikację zmian w reżimie zmienności – jest to szczególnie istotne w rynku kryptowalut, który cechuje się gwałtownymi przejściami między spokojnymi a bardzo zmiennymi. Włączenie tego bloku zmiennych daje modelowi LSTM możliwość uchwycenia dynamicznych przejść rynkowych, które mogą nie być widoczne w samej serii zwrotów.

Nazwa zmiennej	**Opis**	**Ostateczna**
Momentum (k-dniowy)	Siła trendu – różnica ceny zamknięcia dziś i sprzed kk dni (dla k=5,10,20k=5,10,20).	Nie
Rolling Volatility (k-dniowa)	Odchylenie standardowe log-zwrotów w oknie kk (dla k=14,30k=14,30); ocena ryzyka krótkoterminowego.	Tak
Parkinson Realized Volatility	Miernik zmienności oparty o różnicę High–Low, bardziej efektywny niż klasyczne wskaźniki z cen zamknięcia.	Tak
Volatility Ratio	Stosunek krótkoterminowej do długoterminowej zmienności (np. 5-dniowej do 20-dniowej); informacja o zmianie reżimu ryzyka.	Nie

Tabela 5. Zmienne momentum i zmienności wykorzystane w modelach LSTM (opracowanie własne)

Model 5 – Zmienne Techniczne

Wskaźniki techniczne od dekad stanowią podstawę analizy rynków finansowych (Achelis, 2001; Murphy, 1999). W przypadku Bitcoina ich przydatność została potwierdzona empirycznie (np. Gerritsen i in., 2020). Strategie oparte na średnich kroczących i wybiciach z kanałów cenowych generują ponadprzeciętne wyniki w dłuższych okresach. RSI i MACD to klasyczne mierniki momentum, które pomagają wykrywać stany wykupienia i odwrócenia trendu. ADX wskazuje na siłę trendu, a flagi EMA/SMA służą jako filtry reżimowe oddzielające fazy hossy od bessy. Z kolei Donchian breakout to jeden z najbardziej rozpoznawalnych sygnałów analizy technicznej, popularny w strategiach typu śledzenie trendu. Włączenie tych zmiennych do modelu LSTM pozwala sprawdzić, czy sygnały z analizy technicznej, szeroko stosowane w praktyce, mają również wartość prognostyczną w modelach sekwencyjnych.

Nazwa zmiennej	**Opis**	**Ostateczna**
Relative Strength Index (RSI14)	Miernik siły ruchu cenowego; sygnalizuje wykupienie (>70) i wyprzedanie (<30).	Tak
Exponential Moving Average (EMA14) – flaga	Krótkoterminowy filtr trendu; sygnał kupna, gdy cena powyżej EMA14.	Nie
Simple Moving Average (SMA120) – flaga	Długoterminowy filtr trendu (bull vs bear market).	Nie
Distance from SMA120	Odchylenie ceny od długoterminowego trendu.	Nie
MACD histogram (12,26,9)	Różnica krótkiej i długiej EMA, wygładzona sygnałem; miernik momentum.	Tak
MACD cross – flaga	Klasyczny sygnał kupna/sprzedaży na przecięciu MACD i sygnału.	Tak
Average Directional Index (ADX14)	Siła trendu niezależnie od kierunku; wysokie wartości oznaczają mocny trend.	Nie
Donchian breakout (20 dni) – flaga	Wybicie z kanału cenowego; sygnał kontynuacji lub zmiany trendu.	Nie

Tabela 6. Zmienne techniczne wykorzystane w modelach LSTM (opracowanie własne)

Model 6 – Zmienne on-chain i fundamentalne specyficzne dla Bitcoina

Zmienne specyficzne dla Bitcoina mają charakter fundamentalny i odzwierciedlają zarówno cykliczność podaży, jak i kondycję sieci blockchain. Days since halving bazuje na mechanizmie wbudowanym w protokół BTC – historycznie halvingi prowadziły do znaczących cykli cenowych (Liu i Tsyvinski, 2021). Hashrate jest wskaźnikiem wskaźnikiem kosztu produkcji oraz bezpieczeństwa sieci, a badania (np. Hayes, 2019) pokazują, że koszty wydobycia mogą pełnić rolę fundamentu wyceny BTC. Z kolei MVRV ratio jest popularnym wskaźnikiem z łańcucha bloków (ang. on-chain), który pomaga identyfikować momenty przegrzania rynku (wysokie wartości) oraz dna cyklu (niskie wartości) – co potwierdzają analizy m.in. (Hunady i Sedliacik, 2023). Ten blok zmiennych wprowadza unikalne informacje, które nie występują w klasycznych danych rynkowych, a mogą być kluczowe dla prognozowania cykli BTC.

Nazwa zmiennej	**Opis**	**Ostateczna**
Days since halving	Liczba dni od ostatniego halvingu; odzwierciedla cykl podaży BTC.	Nie
Hashrate / Difficulty	Moc obliczeniowa sieci lub poziom trudności – proxy dla kosztu produkcji i bezpieczeństwa sieci.	Nie
MVRV ratio	Relacja kapitalizacji rynkowej do zrealizowanej; miernik przegrzania lub wyceny niedoszacowanej.	Tak

Tabela 7. Zmienne on-chain i fundamentalne specyficzne dla Bitcoina wykorzystane w modelach LSTM (opracowanie własne)

Model 7 – Zmienne Makroekonomiczne

Dobór zmiennych do tego modelu został dokładnie wyjaśniony w opisie literatury a także analizie eksploracyjnej.

Nazwa zmiennej	**Opis**	**Ostateczna**
Zwrot S&P 500	Korelacja BTC z rynkiem akcji.	Nie
Zwrot indeksu dolara (DXY)	Miara siły dolara; zwykle odwrotna korelacja z BTC.	Nie
Zwrot złota	Proxy dla „bezpiecznej przystani”.	Nie
Zwrot VIX	Indeks zmienności rynków akcji (strach/ryzyko).	Nie

Zwrot obligacji 10Y	Rentowność obligacji długoterminowych	Nie
Zwrot BCOM Index	Ogólny indeks surowców.	Tak
Zwrot ropy WTI	Kluczowy surowiec dla inflacji.	Nie
CPI (inflacja)	Wskaźnik cen konsumenckich, forward-fill na dane dzienne.	Nie
M2 (podaż pieniądza)	Miara płynności w gospodarce.	Nie
Fed Funds Rate	Podstawowa stopa krótkoterminowa FED, forward-fill na dane dzienne.	Nie

Tabela 8.Zmienne makroekonomiczne wykorzystane w modelach LSTM (opracowanie własne)

Dobór ostatecznych zmiennych

Pierwszym krokiem była wstępna ocena przydatności zmiennych. Do tego celu wykorzystano algorytm XGBoost, który jest wydajnym modelem opartym na drzewach zespołowych. Na jego podstawie obliczono permutacyjną miarę istotności zmiennych, czyli miernik polegający na sprawdzaniu, jak zmienia się dokładność prognozy po losowym przemieszaniu wartości danej cechy. Jeżeli pogorszenie jakości było wyraźne, oznaczało to, że zmienna ma wysoką wartość informacyjną.

Na drugim etapie startowano od zmiennej bazowej (log-zwrot BTC). Do niej stopniowo dodawano kolejne cechy z listy wyłonionej w etapie pierwszym. Po każdym dodaniu trenowano model LSTM i sprawdzano, czy jakość prognozy ulega poprawie – oceniano to głównie na podstawie błędu średniokwadratowego (RMSE), ale też trafności kierunku prognozy (hit rate). Jeśli dodanie zmiennej poprawiało wynik, pozostawała ona w modelu; jeśli nie – proces selekcji zatrzymywano.

Tak skonstruowana ścieżka doboru zmiennych pozwoliła:

- pozbyć się zmiennych nadmiarowych już na etapie pierwszym,
- zachować tylko te cechy, które rzeczywiście zwiększały skuteczność prognoz,
- uniknąć przeuczenia i uzyskać kompromis między liczbą zmiennych a prostotą końcowej architektury modelu.

3.4 Metody oceny efektywności modelu

3.4.1 Metryki błędu

W celu oceny jakości modeli predykcyjnych w analizie szeregów czasowych wykorzystuje się różne miary błędu, które pozwalają porównać dopasowanie prognoz do wartości rzeczywistych. W niniejszej pracy zastosowano trzy metryki: średni błąd bezwzględny (MAE), pierwiastek średniego błędu kwadratowego (RMSE) oraz trafność kierunku prognozy (hit rate). Każda z nich mierzy nieco inny aspekt jakości prognozy, a ich łączne zastosowanie daje pełniejszy obraz skuteczności modelu.

1. Średni błąd bezwzględny (MAE)

Średni błąd bezwzględny jest jedną z najprostszych i najbardziej intuicyjnych miar jakości prognoz. Oblicza się go jako średnią arytmetyczną wartości bezwzględnych różnic między prognozami a wartościami rzeczywistymi:

$$MAE = \frac{1}{n}\sum_{t-1}^{n} | y_t - \widehat{y_t} |$$

gdzie:

y_t – wartość rzeczywista w chwili t,

$\widehat{y_t}$ – prognoza modelu w chwili t,

n – liczba obserwacji w zbiorze testowym.

MAE mierzy przeciętną wielkość błędu bez względu na jego kierunek (niedoszacowanie i przeszacowanie liczone są tak samo). Jego interpretacja jest prosta – informuje, o ile jednostek przeciętnie myli się model. W kontekście log-zwrotów kryptowalut MAE pozwala ocenić, jak duże są typowe odchylenia prognozy od rzeczywistej wartości.

2. Pierwiastek średniego błędu kwadratowego (RMSE)

Drugą miarą jest pierwiastek średniego błędu kwadratowego:

$$RMSE = \sqrt{\frac{1}{n}\sum_{t-1}^{n} (y_t - \widehat{y_t})^2}$$

gdzie:

y_t – wartość rzeczywista w chwili t,

$\widehat{y_t}$ – prognoza modelu w chwili t,

n – liczba obserwacji w zbiorze testowym.

Podobnie jak MAE, RMSE mierzy różnicę między prognozami a wartościami rzeczywistymi, ale dodatkowo silniej karze duże błędy, ponieważ różnice są podnoszone do kwadratu. Dzięki temu RMSE jest szczególnie użyteczne w analizie szeregów finansowych, które cechują się epizodami nagłych i dużych wahań. Wysoka wartość RMSE wskazuje, że model często popełnia duże błędy w prognozie, a niska – że przewidywania są bliskie wartościom rzeczywistym.

W interpretacji praktycznej RMSE, w przeciwieństwie do MAE, jest bardziej wrażliwe na obserwacje odstające. Dlatego obie miary stosuje się komplementarnie – MAE pokazuje „typowy" błąd, natomiast RMSE ujawnia, jak dobrze model radzi sobie w momentach większej zmienności.

3. Trafność kierunku prognozy (Hit Rate)

W przypadku aktywów finansowych, takich jak Bitcoin, inwestorów interesuje nie tylko wielkość prognozowanych zwrotów, lecz także poprawne wskazanie ich kierunku – czy cena w kolejnym okresie wzrośnie, czy spadnie. Do oceny tego aspektu stosuje się miarę trafności kierunku, zwaną hit rate:

$$HitRate = \frac{1}{n}\sum_{t=1}^{n}\left(sign(y_t) = sign(\widehat{y_t})\right)$$

gdzie:

y_t – wartość rzeczywista w chwili t,

$\widehat{y_t}$ – prognoza modelu w chwili t,

$sign(\cdot)$ – funkcja znaku (+1 dla wartości dodatnich, −1 dla ujemnych, 0 dla zera),

$1(\cdot)$ – funkcja wskaźnikowa: zwraca 1, jeśli warunek jest spełniony, w przeciwnym razie 0,

n – liczba obserwacji w zbiorze testowym.

Hit rate mierzy udział poprawnie przewidzianych kierunków zmian w całkowitej liczbie prognoz. Wartość 0.5 oznacza losowe trafianie (jak rzut monetą), wartości powyżej 0.5 wskazują na skuteczność modelu w przewidywaniu kierunku ruchu. Ta miara ma szczególne znaczenie praktyczne – nawet jeśli prognozowane wartości liczbowe odbiegają od rzeczywistych, poprawne wskazanie kierunku zmiany może stanowić podstawę zyskownej strategii inwestycyjnej.

3.4.2 Walidacja wyników na zbiorze testowym.

W celu oceny skuteczności modeli zastosowano chronologiczny podział danych na trzy zbiory: uczący (do 31 grudnia 2021 r.), walidacyjny (rok 2022) oraz testowy (od 1 stycznia 2023 r.). Dane uporządkowano czasowo, aby zachować zgodność z rzeczywistym przebiegiem zdarzeń i uniknąć wycieku informacji z przyszłości. Zbiór walidacyjny służył do monitorowania jakości uczenia się modelu i kontroli przeuczenia z wykorzystaniem mechanizmu wczesnego zatrzymania – proces uczenia był przerywany, gdy błąd na zbiorze walidacyjnym przestawał się poprawiać, a następnie przywracano zestaw wag modelu odpowiadający najlepszym wynikom.

Zrezygnowano z walidacji kroczącej ze względów obliczeniowych. W pracy analizowano kilka wariantów modeli oraz prowadzono selekcję cech metodą krokową do przodu, co wymagało wielokrotnego trenowania. Zastosowanie walidacji kroczącej oznaczałoby konieczność setek dodatkowych iteracji i wielogodzinnych obliczeń. Ocenę wpływu walidacji kroczącej pozostawiono jako potencjalny kierunek dalszych badań.

4 Wyniki i analiza

W tym rozdziale przedstawiam wyniki działania zastosowanych modeli i porównuję ich skuteczność przy użyciu spójnych miar i zasad oceny. Pokazuję, jak różne zestawy zmiennych i typy modeli wpływają na dokładność prognoz w krótkim horyzoncie czasowym, a na końcu omawiam, co z tych wyników wynika w praktyce i jakie są ich ograniczenia.

4.1 Wyniki działania modeli predykcyjnych

ARIMA

W przypadku modelu ARIMA zastosowano konfigurację wybraną automatycznie przez procedurę auto_arima, czyli ARIMA (0,0,0) z wyrazem wolnym. Jest to model równoważny procesowi białego szumu z niezerową średnią, co oznacza, że prognozy opierają się wyłącznie na stałej wartości średniej log-zwrotów BTC.

Dopasowanie oceniono na podstawie standardowych miar błędu:

Metryka	**MAE**	**RMSE**	**Hit Rate**
Wynik	0.01727	0.02465	0.4961

Tabela 9. Wyniki modelu ARIMA

Interpretacja

Uzyskane wartości błędów należą do najniższych spośród wszystkich estymowanych modeli, co częściowo wynika z faktu, że okres testowy obejmował fazę względnie stabilnych, umiarkowanie wzrostowych notowań BTC. W takich warunkach prognoza stałą średnią nie prowadzi do dużych odchyleń. Niemniej jednak przewidywania modelu ARIMA nie mają większej wartości poznawczej – są pozbawione informacji o dynamice procesu i sprowadzają się do stałej wartości oczekiwanej. Model pełni więc funkcję minimalnego punktu odniesienia, względem, którego można oceniać, czy bardziej złożone modele (np. LSTM) wnoszą dodatkową wartość predykcyjną.

Warto jednak zaznaczyć, że relatywnie niski błąd jest w dużej mierze efektem dopasowania średniej z okresu treningowego do średniej z okresu testowego. Gdyby test przypadał na bardziej dynamiczny okres – np. spadkowy – błędy prognozy prawdopodobnie byłyby wyższe.

LSTM

Model	Blok zmiennych	MAE	RMSE	Directional Accuracy / Hit Rate
ARIMA	Autokorelacja (log-zwroty)	**0.01727**	**0.02465**	0.4961
LSTM 1	Autokorelacja (log-zwroty)	0.01772	0.02522	0.4907
LSTM 2	Zmienne wolumenowe	0.01741	0.02490	0.4932
LSTM 3	Zmienne świecowe (OHLC)	0.01737	0.02482	0.5128
LSTM 4	Momentum i zmienność	**0.01735**	**0.02477**	0.4985
LSTM 5	Zmienne techniczne	0.01750	0.02493	0.4819
LSTM 6	Zmienne specyficzne dla BTC	0.01752	0.02485	0.4798
LSTM 7	Zmienne makroekonomiczne	0.01771	0.02516	**0.5124**

Tabela 10. Porównanie wyników modeli ARIMA oraz LSTM ze wszystkimi blokami zmiennych

Interpretacja wyników

Tabela przedstawia wyniki modeli ARIMA oraz LSTM zbudowanych w oparciu o różne bloki zmiennych. Widać, że wszystkie modele uzyskały bardzo zbliżone wartości błędów MAE i RMSE – różnice mieszczą się w czwartej cyfrze po przecinku. Najniższe błędy odnotowano dla modeli LSTM z blokiem zmiennych momentum i zmienności (MAE=0.01735, RMSE=0.02477) oraz świecowych (MAE=0.01737, RMSE=0.02482). Nie ma jednak poprawy względem prostego modelu ARIMA choć różnica jest minimalna.

Pod względem trafności kierunku prognozy (hit rate) najlepiej wypadły modele LSTM oparte na zmiennych świecowych (0.5128) i makroekonomicznych (0.5124). Wyniki te oscylują wokół poziomu losowego zgadywania (0.50), co wskazuje, że żadna z zastosowanych architektur nie potrafi w sposób znaczący przewidywać kierunku kolejnych dziennych log-zwrotów BTC. Warto jednak podkreślić, że te dwa bloki zmiennych dały minimalną poprawę względem losowości, co może sugerować, że w określonych warunkach rynkowych niosą dodatkową informację.

Podsumowując ARIMA okazał się solidnym punktem odniesienia – osiągnął najniższy błąd i stabilny hit rate. Z kolei modele LSTM nie poprawiły znacząco jakości predykcji błędów, co potwierdza trudność przewidywania dziennych zwrotów BTC. Największą wartość dodaną

LSTM można zauważyć w minimalnie wyższym hit rate przy wykorzystaniu zmiennych świecowych i makroekonomicznych.

Wyniki te są spójne częścią literatury, która podkreśla, że w krótkim horyzoncie log-zwroty kryptowalut zachowują się w dużej mierze jak proces losowy, a potencjalne przewagi predykcyjne są krótkotrwałe i trudne do uchwycenia.

4.2 Porównanie efektywności zastosowanych metod

W celu oceny skuteczności zastosowanych podejść porównano wyniki modelu klasycznego ARIMA z modelami LSTM zbudowanymi w różnych konfiguracjach zmiennych objaśniających. Naszym modelem porównawczym pozostaje ARIMA (0,0,0), który w praktyce odpowiada procesowi błądzenia losowego z niezerową średnią i stanowi minimalny punkt odniesienia.

Analiza wyników wskazuje, że:

Model LSTM – niezależnie od doboru bloków zmiennych - osiągnął wyniki zbliżone do modelu porównawczego. Dodanie zmiennych technicznych czy on-chain przynosiło nieznaczną poprawę w wybranych konfiguracjach, jednak różnice były zbyt niewielkie by można było je uznać za istotne.

Blok zmiennych makroekonomicznych nie przyczynił się do istotnej poprawy trafności prognoz w krótkim horyzoncie T+1, mierzonej wskaźnikiem RMSE. Odnotowano co prawda nieznaczny wzrost miary przewidywania kierunku, jednak nie można go uznać za istotny, gdyż różnica na poziomie 1,5 p.p. względem modelu bazowego jest zbyt niewielka, aby stanowiła dowód na realną przewagę modelu. Uzyskane wyniki sugerują, że zmienność Bitcoina oraz dominacja czynników endogenicznych rynku sprawiają, iż sygnały makroekonomiczne ujawniają się przede wszystkim w dłuższych horyzontach czasowych a ich wpływ jest okresowy, co pozostaje w zgodzie z ustaleniami wcześniejszych badań.

Podsumowując, przeprowadzona analiza wskazuje, że w horyzoncie jednodniowym model LSTM, reprezentujący podejście uczenia maszynowego, nie przewyższa prostego modelu odniesienia ARIMA. Wynik ten pozostaje w zgodzie z hipotezą efektywności rynku w słabej formie, według której log-zwroty aktywów finansowych są w dużej mierze nieprzewidywalne. Warto jednak zaznaczyć, że brak przewagi złożonych architektur w moim badaniu nie oznacza ich bezużyteczności – literatura wskazuje bowiem, że mogą one dostarczać lepszych rezultatów w dłuższych horyzontach prognozy oraz w modelowaniu zmienności. Uzyskany rezultat można

tłumaczyć ograniczoną możliwością przewidywania przyszłych zdarzeń na rynkach finansowych.

4.3 Znaczenie zmiennych w predykcji cen Bitcoina

Aby ocenić, które zmienne w największym stopniu wpływają na jakość prognoz, zastosowano dwustopniową procedurę selekcji. W pierwszym etapie wykorzystano permutacyjną miarę istotności zmiennych (ang. permutation importance) w modelu XGBoost, służącą do preselekcji predyktorów. Metoda ta ocenia znaczenie zmiennej poprzez pomiar spadku jakości prognozy po losowym przetasowaniu jej wartości. W drugim etapie przeprowadzono selekcję krokową do przodu, polegającą na iteracyjnym dodawaniu kolejnych predyktorów i ocenie, czy ich włączenie prowadzi do istotnej poprawy dopasowania modelu.

Wyniki analizy

Szczegółowe wartości istotności zmiennych przedstawiono w rozdziale 4.1. W skrócie, analiza permutation importance wskazała, że spośród czynników makroekonomicznych relatywnie najwyższe znaczenie miały m.in. agregat podaży pieniądza M2 oraz wskaźnik rynków towarowych, indeks BCOM. Jednak sygnały te były bardzo słabe – różnice w jakości prognoz po permutacji zmiennych mieściły się w granicach błędu. Co istotne, mimo że M2 uzyskało najwyższą rangę w permutation importance, nie zostało ono uwzględnione w ostatecznym modelu po selekcji krokowej. Ostatecznie do modelu weszły jedynie log-zwroty BTC oraz zwroty indeksu BCOM.

Interpretacja

Uzyskane wyniki potwierdzają, że w krótkim horyzoncie T+1 znaczenie zmiennych makroekonomicznych w predykcji zwrotów Bitcoina jest marginalne. Wprawdzie analiza permutation importance sugerowała, że takie czynniki jak M2 mogą zawierać pewien sygnał informacyjny, to jednak jego siła była zbyt mała, by przełożyć się na poprawę jakości prognoz w obecności innych predyktorów. Pokazuje to, że powiązania między rynkiem kryptowalut a otoczeniem makroekonomicznym istnieją, ale są słabe i niestabilne w prognozach jednodniowych zwrotów. Zbieżne wnioski raportuje literatura, wskazując, że wpływ czynników makroekonomicznych ujawnia się raczej w dłuższych horyzontach oraz w modelach zmienności niż w prognozach krótkoterminowych.

Podsumowując, analiza wykazała, że jedynie pojedyncze zmienne wnosiły nieznaczny, istotny wkład, natomiast większość predyktorów pozostawała nieprzydatna w prognozowaniu jednodniowych zwrotów

4.4 Dyskusja nad wynikami i ich praktycznym zastosowaniem

Uzyskane wyniki wskazują, że model LSTM, nie oferuje istotnej przewagi prognostycznej nad minimalnym punktem odniesienia (jakim był model ARIMA(0,0,0) ze stałą) w przewidywaniu jednodniowych logarytmicznych stóp zwrotu Bitcoina. Różnice pomiędzy modelami w zakresie RMSE i MAE okazały się marginalne, a wskaźniki trafności kierunku zmian oscylowały wokół 50%, co jest zgodne z hipotezą błądzenia losowego i słabą formą efektywności rynku (Fama, 1970; Samuelson, 1965). Wynik ten koresponduje z literaturą, która wskazuje, że krótkookresowe zwroty finansowe, w tym zwroty Bitcoina, są w dużej mierze nieprzewidywalne (Urquhart, 2016; Bariviera, 2017) a modele uczenia maszynowego rzadko dają przewagi nad prostymi benchmarkami (Aminimehr i in., 2022; Beck i in., 2025)

Wyniki te kontrastują z badaniami, które raportowały bardzo niskie błędy prognoz i wysoką skuteczność modeli ML/DL w przypadku prognozowania rynków finansowych i kryptowalut. Fischer i Krauss (2018) pokazali, że sieci LSTM przewyższają klasyczne modele w prognozowaniu indeksu S&P500, a wiele prac dotyczących kryptowalut wskazywało na wysokie dopasowanie modeli głębokich, zwłaszcza gdy analizowano nominalne ceny BTC zamiast log-zwrotów (Duta i in., 2020; Goodel i in., 2023). Różnice jednak między wynikami modeli bardziej złożonych a prostych benchmarków są często marginalne. Należy również zauważyć, że wyniki „spektakularne" były często efektem uchwycenia trendów w niestacjonarnych szeregach czasowych, a nie rzeczywistej zdolności predykcyjnej (Granger i Newbold, 1974). Dodatkowo, częstą praktyką jest również raportowanie wysokich wyników bez dodania punktu odniesienia.

W niniejszej pracy przyjęto bardziej rygorystyczne podejście: analizowano log-zwroty, zastosowano walidację chronologiczną i porównanie z prostym modelem ARIMA. To pozwoliło uniknąć typowych pułapek metodologicznych, ale jednocześnie ujawniło realne ograniczenia w prognozowaniu krótkoterminowych stóp zwrotu Bitcoina. Otrzymane rezultaty wpisują się w nurt literatury, który wskazuje, że przewaga złożonych modeli nad prostymi jest minimalna lub nieistotna w krótkim horyzoncie (Shintate i Pichl, 2019; Krähenbühl i Osterrieder, 2022)

Włączenie dodatkowych bloków zmiennych, w tym wskaźników technicznych, zmiennych on-chain oraz czynników makroekonomicznych, nie doprowadziło do znaczącej poprawy jakości prognoz. Wyniki te potwierdzają wnioski literatury, zgodnie z którymi czynniki makroekonomiczne mają większe znaczenie w średnich i długich horyzontach czasowych, natomiast w prognozach jednodniowych log-zwrotów sygnał jest słaby i często maskowany przez przypadkową zmienność (Krähenbühl i Osterrieder, 2022; Park i Lee, 2023). Tym samym przeprowadzone badanie potwierdza, że Bitcoin coraz silniej wpisuje się w globalny system finansowy, jednak w krótkim horyzoncie jego zachowanie pozostaje zgodne z teorią efektywnego rynku.

Podsumowując, otrzymane wyniki są zgodne z literaturą krytyczną wobec wcześniejszych „spektakularnych" osiągnięć modeli ML/DL w prognozowaniu Bitcoina. Realistyczne podejście, uwzględniające rygorystyczną walidację i analizę log-zwrotów, prowadzi do wniosku, że na horyzoncie jednodniowym przewaga modeli głębokiego uczenia nad prostymi benchmarkami praktycznie nie istnieje. Oznacza to, że badania wskazujące na wysoką przewidywalność cen lub zwrotów BTC należy traktować z dużą ostrożnością, a wiarygodna analiza powinna skupiać się raczej na dłuższych horyzontach lub na prognozie zmienności zamiast samych zwrotów.

5 Wnioski

Przeprowadzone badania empiryczne pozwoliły ocenić skuteczność klasycznych oraz nowoczesnych metod prognozowania zwrotów logarytmicznych Bitcoina w horyzoncie jednodniowym. Prosty model ARIMA (0,0,0), oznaczający biały szum wokół średniej niezerowej, zastosowany jako punkt odniesienia, okazał się wystarczającym konkurentem dla bardziej złożonych modeli w tym krótkim horyzoncie. Modele LSTM, mimo swojej złożoności i zdolności do modelowania nieliniowych zależności, nie przyniosły istotnej poprawy jakości prognoz. W ramach badań opracowano siedem wariantów modeli, z których każdy wykorzystywał blok z szerokim zestawem zmiennych reprezentujących różne informacje. Zmienne makroekonomiczne, będące głównym przedmiotem analizy, podobnie jak pozostałe zmienne, nie przyczyniły się jednak do istotnej poprawy trafności prognoz w krótkim horyzoncie. Wyniki te potwierdzają, że krótkoterminowe zmiany cen Bitcoina mają w dużej mierze charakter losowy, co jest zgodne z hipotezą efektywności rynku.

Analiza eksploracyjna wykazała, że Bitcoin coraz silniej reaguje na czynniki makroekonomiczne, zwłaszcza po 2020 roku. Rosnące korelacje z indeksem S&P 500, rentownościami obligacji czy wskaźnikami inflacji, a także reakcje na politykę monetarną świadczą o jego coraz większym powiązaniu z tradycyjnymi rynkami finansowymi. Mimo to w ujęciu dziennym znaczenie zmiennych makroekonomicznych pozostaje marginalne – poprawa wskaźników błędów się nie poprawiła, podczas gdy prognoza kierunku poprawiła się bardzo nieznacznie. Bitcoin, choć coraz częściej zachowuje się jak klasyczne instrumenty finansowe, zachowuje pewne unikatowe właściwości, takie jak skończona podaż, czteroletnie cykle halvingów czy dane on-chain, które mogą dostarczać dodatkowych informacji o dynamice jego rynku.

Przedstawione badania mają kilka istotnych ograniczeń. Po pierwsze, analizy koncentrowały się wyłącznie na krótkim horyzoncie (T+1), co ogranicza możliwość oceny długookresowych zależności i efektów akumulacji błędów. Po drugie, wykorzystano stosunkowo ograniczony zestaw modeli – głównie ARIMA i LSTM – bez pełnej optymalizacji hiperparametrów i porównania z innymi podejściami nieliniowymi. Po trzecie, specyfika rynku Bitcoina, charakteryzującego się dużą zmiennością, zmianami strukturalnymi i rosnącą dojrzałością, powoduje, że wyniki mogą ewoluować wraz z dalszym rozwojem rynku i napływem nowych danych.

Kierunki dalszych badań mogą obejmować prognozowanie w dłuższych horyzontach oraz prognozowanie zmienności zamiast samych zwrotów. Warto rozważyć zastosowanie modeli klasyfikacyjnych ukierunkowanych na przewidywanie kierunku zmian oraz bardziej zaawansowane metody uczenia głębokiego, takie jak GRU czy transformery. Interesującym kierunkiem dalszych badań mogłaby być również pogłębiona analiza związków między danymi on-chain, wskaźnikami makroekonomicznymi i zachowaniem ceny Bitcoina. W szczególności można rozważyć badanie punktów zwrotnych rynku (minimów i maksimów) oraz długookresowych cykli koniunkturalnych w ujęciu wizualnym i statystycznym, integrując elementy analizy technicznej z analizą makroekonomiczną.

6 Bibliografia

Abdullaev, N., Ibragimov, R., 2025. Stylized Facts of Cryptocurrency Markets: Robust Definitions and Inference Approaches. SSRN Working Paper

Achelis, S.B., 2001. Technical Analysis from A to Z (2nd ed.). New York: McGraw-Hill.

Aminimehr, A., Raoofi, A., Aminimehr, A., Aminimehr, A., 2022. A Comprehensive Study of Market Prediction from Efficient Market Hypothesis up to Late Intelligent Market Prediction Approaches. Computational Economics, 60(2), 781–815

Anand, P., Sharan, A. M., 2025. Bitcoin Return Dynamics Volatility and Time Series Forecasting. International Journal of Financial Studies, 13(2), 108

Atsalakis, G.S., Valavanis, K.P., 2009. Surveying Stock Market Forecasting Techniques-Part II: Soft Computing Methods. Expert Systems with Applications, 36, 5932-5941

Avdjiev, S., Bruno, V., Koch, C., 2019. The Dollar Exchange Rate as a Global Risk Factor: Evidence from Investment. IMF Economic Review, 67, 151-173

Bariviera, A. F., 2017. The inefficiency of Bitcoin revisited: A dynamic approach. Economics Letters, 161, 1–4

Baur, D. G., Hong, K., Lee, A. D., 2018. Bitcoin: Medium of exchange or speculative assets? Journal of International Financial Markets, Institutions and Money, 54, 177–189

Beck, N., Dovern, J., Vogl, S., 2025. Mind the naive forecast! A rigorous evaluation of forecasting models for time series with low predictability. Applied Intelligence, 55, Article 395

Ben Brayek, A., Ben Ameur, H., Alharbi, F. M. 2024. The Importance of Bitcoin and Commodities as Investment Diversifiers in OPEC and Non-OPEC Countries. Economies, 12(12), 351

Bengio, Y., Simard, P., Frasconi, P., 1994. Learning long-term dependencies with gradient descent is difficult. IEEE Transactions on Neural Networks, 5(2), 157–166

Benigno, G., Rosa, C., 2023. The Bitcoin–Macro Disconnect. FRBNY Staff Report No. 1052.

Bollerslev, T., 1986. Generalized autoregressive conditional heteroskedasticity. Journal of Econometrics, 31(3), 307–327

Box, G.E.P., Jenkins, G.M., 1970. Time Series Analysis: Forecasting and Control. San Francisco: Holden-Day.

Caporale, G.M., Plastun, A., 2020. Momentum effects in the cryptocurrency market after one-day abnormal returns. Financial Markets and Portfolio Management. Swiss Society for Financial Market Research, 34(3), 251-266

Che, N., Copestake, A., Furceri, D., Terracciano, T., 2023. The Crypto Cycle and US Monetary Policy. IMF Working Paper 2023/163. International Monetary Fund.

Chen, T., Guestrin, C., 2016. XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, San Francisco, 13-17 August 2016, 785-794

Cho, K., Van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., Bengio, Y., 2014. Learning Phrase Representations Using RNN Encoder-Decoder for Statistical

Machine Translation. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP), Doha, October 2014, 1724-1734

Choi, K., Shin, S., 2022. Bitcoin: An inflation hedge but not a safe haven. Finance Research Letters, 46

Cont, R., 2001. Empirical properties of asset returns: Stylized facts and statistical issues. Quantitative Finance, 1(2), 223–236

De Luca, G., Montanino, A., 2025.Cryptocurrency Market Dynamics: Copula Analysis of Return and Volume Tails. Risks, 13(9), 168

Díaz, E., Cunado J., Perez de Garcia F., 2023. Commodity price shocks, supply chain disruptions and U.S. inflation. Finance Research Letters, 58, 104495

Dickey, D.A., Fuller, W.A., 1979. Distribution of the estimators for autoregressive time series with a unit root. Journal of the American Statistical Association, 74(366), 427–431

Dutta, A., Kumar, S., Basu, M., 2020. A Gated Recurrent Unit Approach to Bitcoin Price Prediction. Journal of Risk and Financial Management, 13(2),1-16

ECB, 2020. The International Role of the Euro. European Central Bank, Frankfurt am Main

Enders, W., 2014. Applied Econometric Time Series. 4th ed. Hoboken, NJ: John Wiley & Sons

Engle, R.F., 1982. Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of U.K. Inflation. Econometrica, 50(4), 987–1007

Fama, E. F., 1970. Efficient Capital Markets: A Review of Theory and Empirical Work. The Journal of Finance, 25(2), 383–417

Fischer, T., Krauss, C., 2018. Deep learning with long short-term memory networks for financial market predictions. European Journal of Operational Research, 270(2), 654–669

Gerritsen, D. F., Bouri, E., Ramezanifar, E., Roubaud, D., 2020. The profitability of technical trading rules in the Bitcoin market. Finance Research Letters, 34, 101263.

Gers, F. A., Schmidhuber, J., Cummins, F., 2000. Learning to Forget: Continual Prediction with LSTM. Neural Computation, 12(10), 2451–2471

Goodell, J.W., Ben Jabeur, S., Saâdaoui, F., Nasir, M.A., 2023. Explainable artificial intelligence modeling to forecast bitcoin prices. International Review of Financial Analysis, 88, 102702

Goodfellow, I., Bengio, Y., Courville, A., 2016. Deep Learning. Cambridge, MA: MIT Press

Granger, C.W.J., Newbold, P., 1974. Spurious regressions in econometrics. Journal of Econometrics, 2(2), 111–120

Gu, S., Kelly, B., Xiu, D., 2020. Empirical Asset Pricing via Machine Learning. The Review of Financial Studies, 33(5), 2223–2273

Hastie, T., Tibshirani, R., Friedman, J., 2009. The Elements of Statistical Learning: Data Mining, Inference, and Prediction. Stanford, CA: Stanford University

Hau L., Huiming Z., Muhhamad S., Wuqin S., 2021. Does transaction activity predict Bitcoin returns? Evidence from quantile-on-quantile analysis. The North American Journal of Economics and Finance, 55, 101297

Hayes, A. S., 2019. Bitcoin price and its marginal cost of production: support for a fundamental value. Applied Economics Letters, Taylor & Francis, 26(7), 554-560

Hochreiter, S., Schmidhuber, J., 1997. Long Short-Term Memory. Neural Computation, 9(8), 1735–1780

Hyndman, R.J., Athanasopoulos, G., 2021. Forecasting: Principles and Practice (3rd ed.)

Ibrahim, B. A., Elamer, A. A., Alasker, T. H., Mohamed, M. A., Abdou, H. A., 2024. Volatility contagion between cryptocurrencies, gold and stock markets pre-and-during COVID-19: Evidence using DCC-GARCH and cascade-correlation network. Financial Innovation, 10(1), 1–28

Jarque, C.M., Bera, A.K., 1987. A test for normality of observations and regression residuals. International Statistical Review, 55(2), 163–172

Johansson J., Vilhelmsson A., 2023. Bitcoin's Price Alchemy: Unravelling the Influence of Macro Announcements on Volatility and Trading Volume in an Era of Rising Inflation. Working paper, SSRN

Kalamen, K., Audoin, A., Solej, R., Pollák, F., 2024. The market dance between the rhythm of bitcoin prices and the S&P 500 Index. 14th International Scientific Conference “Business and Management 2024"

Kartal, C., Öztürk, U. (2022). Analysis of the correlation between cryptocurrencies, S&P500 and us 10-year treasury bond index with granger causality test, Journal of Management and Economics Research, 20, 274-291

Katsiampa, P., 2017. Volatility estimation for bitcoin: a comparison of GARCH models. Economics Letters, 158, 3–6

Klein, T., Pham Thu, H., Walther, T. (2018). Bitcoin Is Not the New Gold—A Comparison of Volatility, Correlation, and Portfolio Performance. International Review of Financial Analysis, 59, 105-116

Krähenbühl, D., Osterrieder, J., 2022. The Efficient Market Hypothesis for Bitcoin in the context of neural networks. arXiv preprint arXiv:2207.14638

Krištoufek, L., 2018. On Bitcoin markets (in)efficiency and its evolution. Physica A: Statistical Mechanics and its Applications, 503, 257–262

Lin, K., Liu, Y., Sun, Q., 2025. Macroeconomic linkages and cryptocurrency markets: Evidence from time-varying correlations. Journal of Financial Stability, 75, 101234.

Lin, M., Liu, Y., Ng Kim Sheng, V., 2025. Analysis of the impact of macroeconomic factors on cryptocurrency returns - Based on quantile regression study, International Review of Economics & Finance, Elsevier, 97

Liu, Y., Tsyvinski, A., 2021. Risks and returns of cryptocurrency. Journal of Financial Economics, 142(2), 248–271

Ma C, Tian Y, Hsiao S, Deng L., 2022. Monetary policy shocks and Bitcoin prices. Research in International Business and Finance, 62, 101711

Magner, N., Hardy, N., 2022. Cryptocurrency forecasting: more evidence of the Meese–Rogoff puzzle. Mathematics, 10(13), 2338

Mandelbrot, B., 1963. The Variation of Certain Speculative Prices. The Journal of Business, 36(4), 394–419

Meese, R.A., Rogoff, K., 1983. Empirical exchange rate models of the seventies: Do they fit out of sample? Journal of International Economics, 14(1–2), 3–24

Murphy, J.J., 1999. Technical Analysis of the Financial Markets. New York: New York Institute of Finance

Nadarajah, S., Chu, J., 2017. On the inefficiency of bitcoin. Economics Letters, 150, 6–9

Panyagometh, K., 2024. The effect of COVID-19 and U.S. monetary policy on Bitcoin and stock market volatility: an application of DCC-GARCH model. Humanities and Social Sciences Communications, 11(1), 1-15

Park, K., Lee, H., 2023. In-sample and out-of-sample predictability of cryptocurrency returns. East Asian Economic Review, 27(3), 213–242

Parkinson, M., 1980. The extreme value method for estimating the variance of the rate of return. Journal of Business, 53(1), 61–65

Paule-Vianez, J., Prado-Román, C., Gómez-Martínez, R., 2020. Economic policy uncertainty and Bitcoin: Is Bitcoin a safe-haven asset? European Journal of Management and Business Economics, 29(3), 347–363

Phillip, A., Chan, J.S.K., Peiris, S., 2018. A new look at cryptocurrencies. Economics Letters, 163, 6–9

Samuelson, P. A., 1965. Proof That Properly Anticipated Prices Fluctuate Randomly. Industrial Management Review, 6(2), 41–49

Seabe, P.L., Mbiyavanga, K.E., Makhaya, K., Modipa, T., 2023. Forecasting Cryptocurrency Prices Using LSTM, GRU, and Bi-Directional LSTM: A Deep Learning Approach. Fractal and Fractional, 7(2), 203

Shapiro, S.S., Wilk, M.B., 1965. An analysis of variance test for normality (complete samples). Biometrika, 52(3–4), 591–611

Shintate, T., Pichl, L., 2019. Trend Prediction Classification for High Frequency Bitcoin Time Series with Deep Learning. Journal of Risk and Financial Management, 12(1), 17

Sims, C.A., 1980. Macroeconomics and Reality. Econometrica, 48(1), 1–48

Smales L. A., 2024. Cryptocurrency as an alternative inflation hedge? Accounting and Finance, 64, 1589-1611

Sung, S.H., Kim, J.M., Park, B.K., Kim., S. 2022. A Study on Cryptocurrency Log-Return Price Prediction Using Multivariate Time-Series Model. Axioms.11(2), 448

Tang, Y., Arias-Calluari, K., Nattagh Najafi, M., Harré, M. S., Alonso-Marroquín, F., 2025. Stylized facts of high-frequency bitcoin time series. Fractal and Fractional, 9(10), 635

Terraza, V., Aityassine, S., Boubaker, S., 2024. The nexus between the volatility of Bitcoin, gold, and American stock markets during the COVID-19 pandemic: evidence from VAR-DCC-EGARCH and ANN models. Financial Innovation, Springer; Southwestern University of Finance and Economics, 10(1), 1-34

Tiwari, A. K., Jana, R. K., Das, D., Roubaud, D., 2018. Informational efficiency of Bitcoin—an extension. Economics Letters, 163, 106–109

Tsay, R. S., 2010. Analysis of Financial Time Series. 3rd ed. Hoboken, NJ: John Wiley & Sons

Urquhart, A., 2016. The inefficiency of Bitcoin. Economics Letters, 148, 80–82

Uzun, I., Lobachev M., Kharchenko V., Scholer R., Lobachev I., 2024. Candlestick Pattern Recognition in Cryptocurrency Price Time-Series Data Using Rule-Based Data Analysis Methods. Computation, 12(7), 132

Vaswani, A., Shazeer, N., Parmar, N., 2017. Attention Is All You Need. Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems, Long Beach, 4-9 December 2017, 5998-6008

Wang L., Sarker P. K., Bouri E., 2023. Short- and Long-Term Interactions Between Bitcoin and Economic Variables: Evidence from the US. Computational Economics, 61(4), 1305-1330

Wang P., Liu, X., Wu S., 2022. Dynamic linkage between Bitcoin and traditional financial assets: A comparative analysis of different time frequencies. Entropy, 24(11), 1565

Wei, J., 2024. Prediction of daily lognormal returns for Bitcoin based on LightGBM. Proceedings of the 1st International Conference on E-commerce and Artificial Intelligence (ECAI 2024), 154–163

Wu, D., 2025. Institutional Adoption and Correlation Dynamics: Bitcoin's Evolving Role in Financial Markets. arXiv:2501.09911

7 Załączniki

7.1 Spis wykresów

Wykres 1. Cena Bitcoina na skali logarytmicznej ujęta w dolarze amerykańskim (USD)..... 23
Wykres 2. Dzienne logarytmiczne stopy zwrotu Bitcoina 24
Wykres 3. Rozkład dziennych zwrotów logarytmicznych bitcoina 25
Wykres 4. Zmienność BTC w czasie (okno kroczące: 30 dni) 26
Wykres 5. Okresowa zmienność BTC w podziale na miesiąc i rok 27
Wykres 6. Okresowa zmienność BTC w podziale na dzień tygodnia i rok 28
Wykres 7. Cena BTC i rentowność obligacji 10Y USA – porównanie w czasie 29
Wykres 8. Korelacja w czasie między BTC a US10Y (okno kroczące: 60 dni) 30
Wykres 9. Cena BTC i Indeksu surowcowego BCOM – porównanie w czasie 31
Wykres 10. Korelacja w czasie między BTC a BCOM (okno kroczące: 180 dni) 31
Wykres 11. Cena BTC i wskaźnika CPI (30-dniowe wygładzenie) – porównanie w czasie... 32
Wykres 12. Średnia dzienna zmienność Bitcoina w dniach publikacji CPI na tle pozostałych dni..... 33
Wykres 13. Dzienna cena Bitcoina i stopa funduszy federalnych (Fed Funds Rate) – porównanie w czasie 34
Wykres 14. Dzienna cena Bitcoina i cena złota – porównanie w czasie 35
Wykres 15. Korelacja w czasie między BTC a indeksem złota (okno kroczące: 180 dni)..... 36
Wykres 16. Dzienna cena BTC i podaż pieniądza M2 – porównanie w czasie 37
Wykres 17. Dzienna cena BTC i indeks dolara – porównanie w czasie 38
Wykres 18. Korelacja w czasie między BTC a indeksem dolara (okno kroczące: 180 dni).... 38
Wykres 19. Dzienna cena BTC i indeks akcji S&P500 – porównanie w czasie..... 39
Wykres 20. Korelacja w czasie między BTC a indeksem S&P500 (okno kroczące: 60 dni).. 40
Wykres 21. Dzienna cena BTC i indeks VIX – porównanie w czasie 41
Wykres 22. Korelacja w czasie między BTC a VIX (okno kroczące: 180 dni)..... 41
Wykres 23. Wykres cenowy BTC podzielony na cykle (każdy kolor oznacza nowy cokl począwszy od halvingu)..... 42
Wykres 24. Schemat działania modelu LSTM (opracowanie własne na podstawie literatury: Gers i in., 2000)..... 45

7.2 Spis Tabel

Tabela 1. Źródła danych makroekonomicznych. 21

Tabela 2. Statystyki opisowe dziennych logarytmicznych stóp zwrotu Bitcoina.....24
Tabela 3. Hiperparametry modelu LSTM.....47
Tabela 4. Zmienne świecowe wykorzystane w modelach LSTM (opracowanie własne).....50
Tabela 5. Zmienne momentum i zmienności wykorzystane w modelach LSTM (opracowanie własne).....50
Tabela 6. Zmienne techniczne wykorzystane w modelach LSTM (opracowanie własne).....51
Tabela 7. Zmienne on-chain i fundamentalne specyficzne dla Bitcoina wykorzystane w modelach LSTM (opracowanie własne).....52
Tabela 8.Zmienne makroekonomiczne wykorzystane w modelach LSTM (opracowanie własne).....53
Tabela 9. Wyniki modelu ARIMA.....57
Tabela 10. Porównanie wyników modeli ARIMA oraz LSTM ze wszystkimi blokami zmiennych.....58

7.3 Streszczenie pracy

Praca koncentruje się na prognozowaniu jednodniowych logarytmicznych stóp zwrotu Bitcoina z wykorzystaniem modeli ARIMA i LSTM. Celem jest porównanie skuteczności metod klasycznych i głębokiego uczenia oraz ocena czy uwzględnienie zmiennych makroekonomicznych poprawia jakość predykcji względem modeli opartych wyłącznie na danych rynkowych. Analiza obejmuje dzienne dane z lat 2014–2025. Zmiennie objaśniające do ostatecznych modeli dobrano spośród cech rynkowych, technicznych i makroekonomicznych na podstawie ważności zmiennych w XGBoost, a następnie selekcji krokowej. Modele oceniono na wydzielonym zbiorze testowym przy użyciu metryk MAE, RMSE i trafności kierunku zmian. Wnioski potwierdzają hipotezę efektywności rynku kryptowalut, a zmienne makroekonomiczne nie pomagają w poprawie jakości prognoz.

7.4 Pozostałe załączniki

Kategoria	Biblioteka / moduł	Zastosowanie
Operacje systemowe i matematyczne	os, math, numpy	operacje numeryczne, funkcje matematyczne
Przetwarzanie i analiza danych	pandas	import, scalanie i transformacja danych
Wizualizacja	matplotlib.pyplot	generowanie wykresów i analiz graficznych
Przygotowanie danych i ocena modeli	sklearn.preprocessing.StandardScaler, sklearn.metrics	standaryzacja zmiennych, obliczanie metryk (MAE, RMSE, R^2)
Modelowanie głębokie	tensorflow, keras.models.Sequential, keras.layers.LSTM, Dense, Dropout, keras.callbacks.EarlyStopping	konstrukcja i trening modelu LSTM, regularyzacja, wczesne zatrzymanie
Selekcja cech i interpretacja	xgboost.XGBRegressor, sklearn.inspection.permutation_importance, scipy.stats.spearmanr	ranking cech, testy korelacji
Kontrola powtarzalności eksperymentów	numpy.random.seed, tensorflow.random.set_seed	ustalenie losowości dla replikowalnych wyników

Tabela użytych w badaniach bibliotek python